



INFORMATIKA
FAKULTATEA
FACULTAD DE
INFORMÁTICA

Gradu Amaierako Lana

Adimen Artifizialeko Gradua

Modalitate-anitzeko arrazoiketa espaziala aztertzen

Jon Elezgarai Miguel

Zuzendariak

Gorka Azkune Galparsoro

2026.eko ekainaren 21

Laburpena

Giza arrazoibide espazialean, informazioa nola aurkezten den erabakigarria da hura ulertzeko. Demagun hainbat elementu (edo nodo) espazioan kokatuta dituen diagrama edo grafo bat daukagula. Adimen Artifizialeko Hizkuntza Eredu Handien (LLM) gaitasunak probatzeko, ohikoa izan da grafiko horietako informazioa testu-deskribapen kateatuen bidez soilik ematea (adibidez, "A B-ren eskuinean dago, eta B C-ren gainean"). Arazoa da, testuzko deskribapen horiek ugaritu eta konplikatu ahala, oso zaila bihurtzen dela urrun dauden bi objekturen arteko erlazio zuzena ondorioztatzea. Aitzitik, giza ikuspuntutik behintzat, askoz naturalagoa eta eraginkorragoa da informazio hori ikusizko diagrama moduan prozesatzea, hots, irudi batean. Irudikapen grafiko bat izanez gero, ataza nabarmen sinplifikatzen da: nahikoa da galderan aipatutako bi nodoak ikusmen bidez bilatu eta kokatzea, eta begiratu batean bata bestearekiko duten posizioa identifikatzea. Lan honen helburu nagusia da aztertzea ea abantaila hori bera errepikatzen den azken belaunaldiko Modalitate Anitzeko Hizkuntza Eredu Erraldoietan (MLLM).

Galdera hori ikertzeko, DecompSR testuzko datu-multzoaren modalitate anitzeko luzapen bat diseinatu da, bi dimentsiotako grafiko espazialak automatikoki sortzeko gai den sistema bat garatuz. 10.816 irudi sortuz, eredu aurreratuen errendimendua ebaluatu da arrazoibide konposizional sakoneko agertokietan. Esperimentuak aldagai desberdinak isolatzeko diseinatu dira, inferentzien konplexutasuna aldatuz (jauzi espazialen kopurua edo *nhop*), testuaren eta irudien erabilera alderatuz, eta laguntza grafiko eta zarata estruktural maila desberdinen eragina ebaluatuz.

Emaitzek hasierako hipotesia berresten dute: gizakien antzera, ikusizko modalitateak egonkortasun handiagoa ematen die MLLMei testuak baino, zeinak errendimendu-kolapso larria jasaten duten konplexutasun espaziala handitu ahala. Hala ere, aurkitu da eredu botila-lepo nagusia ez dagoela arrazoibidean bertan, baizik eta nodoen arreta eta ikusizko identifikazio fasean, muga hori nabarmen hobetzen baita laguntza grafikoa emanez gero (diagrametan bertan, erantzuna errepresentatzen duten pistak sartzea, geziak erabiliz, adibidez).

Gainera, azterlanak aurkikuntza kontraesankorrak erakusten ditu, hala nola modalitate anitzeko erredundantzia (testu-historia irudiarekin batera ematea) kaltegarria dela, testuak zarata gisa jokatzeko baitu, arreta-mekanismoak asetuz. Azkenik, frogatu da arrazoibide esplizituaren erabilera (Thinking modua) ez dela irtenbide unibertsala, eragin desberdina baitu, *Qwen* bezalako ereduetan ikusizko ulermena onuragarria den arren, *Gemma* bezalako ereduetan errendimendu orokorra zigortzen baitu. Ondorioz, lan honek agerian uzten du MLLMek askoz eraginkorrago prozesatzen dutela topologia espaziala ikusmenaren bidez, eta oinarri berriak ezartzen ditu adimen artifizial horiei datuak aurkezteko moduari buruz.

Garapen Jasangarrirako Helburuak

Gradu Amaierako Lan (GrAL) honek Garapen Jasangarriko Helburuen (GJH) barruan, zehazki 9. Helburuari: Industria, Berrikuntza eta Azpiegitura egiten dio ekarpen zuzen eta esanguratsuen. Adimen Artifizialaren (AA) eta, bereziki, Modalitate Anitzeko Hizkuntza Eredu Erraldoietan (MLLM) ikerketa teknologiaren abangoardian kokatzen den eremua da. Eredu hauen arrazoibide espaziala nola funtzionatzen duen ulertzea eta hobetzea ezinbesteko urratsa da etorkizuneko industria eta azpiegitura adimendunak garatzeko.

Alde batetik, ikerketa honetan eredu multimodalen gaitasun espazialak eta mugak aztertu dira, testua eta irudiak nola prozesatzen dituzten alderatuz. Lortutako emaitzek aplikazio praktiko zuzenak dituzte berrikuntza teknologikoan. Adibidez, ibilgailu autonomoek, industria-robotek (biltegietako logistikan edo fabrikazio-kateetan) edota laguntza-sistema bisualek ingurunearen topologia espaziala zehaztasunez ulertu behar dute modu seguru eta eraginkorrean funtzionatzeko. Lan honetan frogatu denez, modalitate anitzeko eredu informazioa ikusizko formatuan (grafoen bidez) aurkeztea askoz ere egonkorragoa eta eraginkorragoa da. Jakintza horrek zuzenean laguntzen du sistema horien garapenean eta hobekuntzan, industria lehiakorrago, seguruago eta berritzaileago bat sustatuz.

Bestetik, jasangarritasun konputazionalaren ikuspuntutik ere ekarpena egiten du lan honek. Esperimentuek agerian utzi dute modalitate anitzeko erredundantziak (testua eta irudia aldi berean emateak) ereduaren arreta-mekanismoak asetzen dituela eta errendimendua okertzen duela zarata gisa jokatuz. Funtzionamendu hori ulertzeak aukera ematen digu etorkizuneko ereduak modu optimoagoan diseinatzeko eta erabiltzeko. Datuen prozesamendu eraginkorrago batek baliabide konputazionalen kontsumoa eta, ondorioz, azterna energetikoa murriztea dakar, adimen artifizialaren garapena bide jasangarriagoetatik bideratuz.

Azkenik, ikerketa irekiaren eta datu-multzoen sorkuntzaren bidez (DecompSR datu-multzoaren luzapen multimodala garatuz), komunitate zientifikoari tresna berri bat eskaintzen zaio. Ekarpen honek ikerketa eta garapen teknologikoa (I+G) bizkortzen laguntzen du, ebaluazio-esparru fidagarriagoak sortuz eta mundu mailako ezagutza teknologikoaren hazkundera bultzatuz, EHUko 2030 Agendak zehazten duen 9. Helburuaren ildoekin bat eginez.

Gaien aurkibidea

Irudien aurkibidea	vii
Taulen aurkibidea	viii
1 Sarrera	1
2 Aurrekariak	3
2.1 Hizkuntza-Eredu Erraldoiak	3
2.1.1 Hizkuntza-ereduen bilakaera	3
2.1.2 Transformer arkitektura	3
2.1.3 Hizkuntza-Eredu Erraldoien agerpena eta eskalatzea	4
2.1.4 Gaitasun nagusiak	4
2.1.5 Testu hutseko LLMen mugak	5
2.1.6 Ikusmen-modalitatea txertatzeko beharra	5
2.2 Modalitate Anitzeko Hizkuntza-Eredu Erraldoiak	5
2.2.1 Definizioa eta Hizkuntza-Eredu Erraldoiekiko desberdintasunak	5
2.2.2 MLLMen arkitektura orokorra	5
2.2.3 Irudi-Testu Prozesamenduaren Fluxua	7
2.2.4 MLLMen zeregin nagusiak	7
2.3 Nola ebaluatu izan da arrazonamendu espaziala MLLMtan?	8
2.4 Lan honetan erabilitako ereduak	9
2.4.1 Qwen3.5-9B	10
2.4.2 InternVL3.5-8B	11
2.4.3 Gemma-4-E4B-it	12
3 Modalitate Anitzeko DecompSR datu-multzoa	13
3.1 Sarrera	13
3.2 Datu-multzoa: DecompSR	14
3.3 Arrazonamendu sakonera (n-hop reasoning)	15
3.4 Datu-multzo originaleko aldaerak	16
3.4.1 Adibide garbiak eta zaratatsuak	16
3.4.2 Adibide nahasiak	18
3.5 Erabilitako datu-multzoaren banaketa	18
3.6 Proposatutako modalitate anitzeko hedapena	19
3.7 Diagramen sortze prozesua	19
3.8 Sortutako ikusizko aldaerak	20
3.9 Sortutako testuzko aldaerak	22


4	Diseinu Esperimentala eta Emaitzak	25
4.1	Esperimentuen Diseinua	25
4.1.1	Exekuzio ingurunea eta inferentzia motorra	25
4.1.2	Emaitzen berregingarritasuna	25
4.1.3	Datu-multzoa eta laginketa-protokoloa	26
4.1.4	Ebaluazio metrika	26
4.1.5	Inferentzia protokoloa	26
4.1.6	Post-prozesaketa eta ebaluazioa	26
4.1.7	Eredu bakoitzaren konfigurazioa	27
4.1.8	Irudien prozesamendua ereduaren ebaluazioan	28
4.1.9	Ondorioa	29
4.2	Emaitzak	29
4.2.1	Datu-multzoko errepresentazio aldaerak	29
4.2.2	Ikusizko eta testuzko errepresentazioen arteko konparaketa	33
4.2.3	Ereduen portaera aztertzen ikusizko sarrerekin	34
4.2.4	Modalite anitzeko sarrera-datuen azterketa	36
4.2.5	Arrazoiketa ereduen ekarpena ebaluatzen	37
4.3	Eztabaida	40
5	Ondorioak eta Etorkizuneko Lana	41
5.1	Ondorio Nagusiak	41
5.2	Etorkizunerako Lana	42
	Eranskinak	43
A	Erabilitako Promptak	43
A.1	0-shot Prompt	43
A.2	5-shot Prompt	44
B	Proiektuaren helburuen dokumentua	47
B.1	Deskribapena eta helburuak	47
B.2	Plangintza	47
B.2.1	Lanaren deskonposaketa egitura	48
B.2.2	Emangarri eta mugarriak	49
B.3	Lan-metodologia	51
B.3.1	Garapena eta baliabideak	51
B.3.2	Komunikazio-sistema	51
B.4	Arriskuak eta prebentzioa	51
C	AA sortzailearen erabilera deklarazioa	53
	Bibliografia	55

Irudien aurkibidea

3.1	Datu instantzia baten adibide sinplea	15
3.2	<i>nhop</i> balioen arabera inferentzia-sakonera. Zenbat eta <i>nhop</i> handiagoa, orduan eta nodo eta erlazio gehiago kateatu behar dira galdera erantzuteko. . .	17
3.3	Adibide garbi eta zaratsuen arteko konparaketa.	18
3.4	Hiru ikusizko aldaeren arteko konparaketa adibide berean. Nodo urdinak galderako entitateak adierazten ditu; gezi urdinak erantzunaren norabide espaziala irudikatzen du.	21
3.5	Grafo errepresentazioen bilakaera: V1, V2 eta V3 bertsioak.	24
4.1	Hiru ereduen errendimendu-kurbak bi konfigurazioetarako (0-shot vs. 5-shot).	30
4.2	Hiru ereduen errendimendu-kurbak testu-modalitateko aldaerentzako (V1, V2, V3).	31
4.3	Hiru ereduen errendimendu-kurbak ikusmen-modalitateko aldaerentzako (V1, V2, V3).	32
4.4	Hiru ereduen errendimendu-kurbak: Testua vs Irudia (T1).	34
4.5	Hiru ereduen errendimendu-kurbak: Irudi-motaren eragina (T2).	36
4.6	Hiru ereduen errendimendu-kurbak: Modalitate Anitzeko Ikuspegia (T3).	38
4.7	Qwen eta Gemma ereduen errendimendu-kurbak: <i>Thinking</i> moduaren eragina testuan eta irudietan.	39
B.1	Proiektuaren plangintza orokorra.	48
B.2	Proiektuaren Gantt diagrama.	50

Taulen aurkibidea

3.1	Datu-multzoko irudien bereizmenen banaketa eta lotutako parametroak. . . .	20
B.1	Lan-pakete bakoitzerako denboraren estimazioa.	50
B.2	Emangarri bakoitzaren epemuga.	51



Sarrera

Arrazoibide espaziala oinarritzko gaitasuna da. Gizakientzat, ingurune fisikoarekin elkarre-
ragiteko, orientatzeko eta inguratzen gaituzten elementuen antolaketa erlatiboa ulertzeko
ezinbestekoa den trebetasuna da. Adimen Artifizialaren arloan, makinei gaitasun hori
ematea, mundu errealeko aplikazio praktiko askotarako ezinbesteko baldintza da. Adibidez,
gorputz fisikoa duten agenteek eta robotika autonomoak, deskribapen eta ikusizko datuetan
oinarrituta, espazio fisikoetan orientatu eta objektuak manipulatu behar dituzte. Era berean,
interfaze grafikoetarako ikusizko laguntzaileek pantailako elementuen topologia espaziala
ulertu behar dute. Aplikazio horiek guztiek sistema konputazionalak ingurunearen egitura
modu sendo eta fidagarrian ulertzea eskatzen dute.

Adimen Artifizialean arrazoibide espazialaren gaitasun hori neurtzeko eta ebaluatzeko
hainbat modu daude, normalean proba-banku (benchmark) estandarizatuen bidez. Hala ere,
proba horietako askok, batez ere testu-eremuan, anbiguotasunak, lasterbide heuristikoak
edo zikloak aurkezten dituzte, arazoaren zailtasun erreala artifizialki murrizten dutenak.
Arrazoibide konposizional sakona modu zorrotzean neurtzeko, ikuspegi sendoenetako
bat DecompsSR datu-multzoan proposatutako zereginak erabiltzea da. Horrelako probek
bermatzen dute inferentzia-jauzien sakonerak (*nhop*) bat egiten duela zehazki planteatutako
agertoki espaziala ebazteko behar den gutxieneko luzerarekin.

Zeregin horiei heltzeko orduan, funtsezko kontua da informazioa aurkezten den forma-
tua edo modalitatea. Gizakietan, topologia espaziala testuzko arauen zerrenda luze gisa
aurkezten bada, karga azkar handitzen da eta oso zaila da bi objektu urrunen arteko erlazio
zuzena ondorioztatzea. Hala ere, gure ikusmen-sistemak informazioa modu globalean
prozesatzen du: irudikapen grafiko bat behatzean, nahikoa da elementuak ikusmenaren
bidez bilatzea haien posizio erlatiboa begirada batean identifikatzeko. Modalitate Anitzeko
Hizkuntza-Eredu Erraldoiak (MLLM) agertzearekin batera —ikusmen artifiziala eta hizkun-
tza naturalaren prozesamendua integratzen dituzten sare neuronaleko sistema sakonetan
oinarrituta—, zeregin espazial horiek modalitate desberdinetan formalizatzeko modua azter-
tzeko beharra sortzen da. Gaur egun, DecompsSR bezalako datu-multzo gehienak testurako
bakarrik diseinatuta daude, eta, beraz, literaturan hutsune bat dago eredu aurreratuak
ikusizko domeinura konplexutasun hori eramaten dutenean duten errendimenduari buruz.

Lan honen helburu nagusia egungo MLLMen arrazoibide espazialaren gaitasunak eba-

luatzea eta fenomeno gizatiarra zenbateraino erreproduzitzen duten aztertzea da: testuzko kate konplexuak prozesatzean kolapsoa jasaten duten zehaztea eta ikusizko modalitateak berez topologia inferentzia errazten duen zehaztea. Horretarako, DecompsSR testu-datuetatik abiatuta, modalitate anitzeko luzapen bat garatu da, milaka ikusizko irudikapen (bi dimentsiotako grafikoak) automatikoki sortuz. Ingurune berri hori erabiliz, hiru eredu aurretaren errendimendua ebaluatu da konfigurazio desberdinetan, konplexutasuna aldatuz (*nhop*), testuzko aldaera desberdinak sartuz eta ikusizko laguntzaren maila aldatuz.

Lortutako emaitzek erakusten dute, hain zuzen ere, ikusizko modalitateak egonkortasun handiagoa ematen diola arrazoibideari testu-sekuentziekin alderatuta, horiek errendimendukolapsoa jasaten baitute konplexutasun espaziala handitu ahala. Hala ere, ikusi da MLLMen botila-lepo nagusia, ikusizko zereginetan, ez dagoela arrazoibidean bertan, baizik eta nodoak identifikatzean eta kokatzean, laguntza grafiko esplizitua gehitzean nabarmen hobetzen den arazoa. Gainera, agerian geratzen da modalitate anitzeko moduaren erredundantzia (testua eta irudia aldi berean ematea) kaltegarria dela, deskribapen-testuinguruak modeloaren arreta-mekanismoak asetzen dituen zarata gisa jotzen baitu. Azkenik, arrazoibide esplizituko teknikak erabiltzea (Thinking modua) irtenbide unibertsala ez dela egiaztatu da, azpiko arkitekturaren arabera ondorio desberdinak dituelarik.

Ondorioz, lan honek agerian uzten du MLLMek topologia espaziala askoz eraginkorrago prozesatzen dutela ikusmenaren bidez, eta oinarri berriak ezartzen ditu adimen artifizial horiei datuak aurkezteko moduari buruz, haien errendimendua maximizatzeko.

Dokumentu hau honela egituratzen da: 2. kapituluari, MLLMei eta arrazoibide espazialari buruzko aurrekari teoriko nagusiak azaltzen dira. 3. kapituluari, erabilitako datu-multzoa eta DecompsSRren modalitate anitzeko luzapenerako garatutako metodologia zehazten dira. 4. kapituluari, aplikatutako diseinu esperimentalak deskribatzen da eta emaitzak sakon aztertzen dira. Azkenik, 5. kapituluari, ondorio nagusiak eta etorkizuneko lan-ildo posibleak aurkezten dira.

Aurrekariak

Kapitulu honek lanaren oinarri teorikoak azaltzen ditu. Lehenik eta behin, Hizkuntza-Eredu Erraldoien (*Large Language Models*, LLM) bilakaera historikoa eta arkitektonikoa deskribatzen da. Ondoren, Modalitate Anitzeko Hizkuntza-Eredu Erraldoien (*Multimodal Large Language Models*, MLLM) paradigma aurkezten da. Hauen arkitektura orokorra, zeregin nagusiak eta egungo mugak azalduko dira, eta baita arrazoiketa espaziala nola ebaluatu izan den. Azkenik, lan honetan erabilitako hiru ereduak zehatz-mehatz deskribatzen dira: *Qwen3.5-9B* [1], *InternVL3_5-8B* [2] eta *Gemma-4-E4B-it* [3].

2.1 Hizkuntza-Eredu Erraldoiak

2.1.1 Hizkuntza-ereduen bilakaera

Hizkuntza-ereduak adimen artifizialeko sistemetan testua ulertzeko eta sortzeko bizkarrezurra dira. N-grametan oinarritutako lehen hurbilketa estatistikoetatik hasi eta gaur egungo eredu neuronaletaraino, hizkuntza-ereduen arloak eraldaketa erradikala izan du, konputazio-ahalmenaren hazkundeak eta testuzko datu-multzo masiboen eskuragarritasunak bultzatuta.

Lehen sare neuronal errepikakorrek (*Recurrent Neural Network*, RNN) eta, ondoren, epe luzeko eta laburreko memoria-sareek (*Long Short-Term Memory*, LSTM) [4] testuan sekuentzia-mendekotasunak modelatzeko aukera eman zuten. Hala ere, oinarritzko mugak zituzten, besteak beste, entrenamendua paralelizatzeko zailtasuna, sekuentzia luzeetan gradiente desagertzea [5] eta milioika parametro eskalatzeko ezintasun praktikoa [6].

2.1.2 Transformer arkitektura

Inflexio-puntu erabakigarria 2017an iritsi zen, *Attention Is All You Need* [7] argitaratu zenean, non *Transformer* arkitektura proposatu zen. Bere ekarpen nagusia buru-anitzeko arreta-mekanismoa (*multi-head self-attention*) da, sekuentzia bateko token bakoitzari beste token guztiengan aldi berean arreta jartzeko aukera ematen diona, haien arteko distantzia posizionala edozein dela ere. Horrek errotik konpontzen du gradiente desagertzearen arazoa eta entrenamenduan zehar paraleloan konputatzeko aukera ematen du.

Transformer arkitekturak, bere kodetzaile eta dekodetzailearen jatorrizko formulazioarekin ohikoak ziren emaitzak hautsi zituen itzulpen automatikoko zereginetan, ingelese-alemana bikoteetan muntatutako sistematik onenek baino 2 BLEU puntu baino gehiagoko hobekuntzarekin[7]. Diseinu honen modalitate eta domeinu berrietara orokortzeak, hurrengo urteetan, aurrekaririk gabeko berrikuntza-bolada bat bultzatu zuen adimen artifizialean.

Arkitekturaren funtsezko osagai bat posizio-kodetzea (*positional encoding*) da, sarrera-bektoreetan ordenaren informazioa injeztatzen duena, errepikapen eza ordezkatzuz. Aldaera modernoek RoPE (*Rotary Position Embedding*)[8] bezalako kodetze birakarietara eboluzionatu dute, gaur egungo LLMetan asko erabiltzen direnak.

2.1.3 Hizkuntza-Eredu Erraldoien agerpena eta eskalatzea

Transformerren dekodetzailearen aldaera, testua modu autoerregresiboan sortzen duena, paradigma nagusi bihurtu zen. *GPT-3*-rekin [6], OpenAIk frogatu zuen parametro kopurua 175.000 milioira arte eskalatzeak, Internetetik ateratako aurrentrenamenduko datuekin batera, ereduari *few-shot* ikaskuntza-gaitasunak erakusteko aukera ematen ziola, doikuntza fin espezifikorik behar izan gabe. Emaitza honek sendotu egin zuen eskalatzea (*scaling*) [9] gaitasun emergenteak sortzen dituen printzipioa dela dioen hipotesia [10].

Eskala handiko hizkuntza-ereduak testuzko datu-multzo masiboetan aurrentrenatzen dira, hizkuntza-eredu kausalaren helburuaren bidez, hurrengo tokena aurreko historiaren arabera iragartzea, alegia. Ondoren, giza jarraibideekin doitze finaren teknika (*instruction fine tuning*) eta giza atzeraelikadurarekin indartze bidezko ikaskuntza (*Reinforcement Learning with Human Feedback*, RLHF) ezinbestekoak direla ikusi da ereduaren portaera erabiltzailearen lehentasunekin lerrokatzeko, InstructGPT-rekin popularizatu zen bezala [11, 6].

2.1.4 Gaitasun nagusiak

LLM modernoek gaitasun sorta izugarri zabala dute. Nabarmenen artean hauek daude:

- **Testuaren ulermena eta sorkuntza:** dokumentuen idazketa, laburpen automatikoa, itzulpena eta parafrasia.
- **Arrazoiketa:** problema matematiko eta logikoen ebazpena, kate-arrazonamendua (*Chain of Thought*) [12].
- **Programazioa:** kodearen sorkuntza, arazketa eta dokumentazioa hainbat programaziolengoiari.
- **Argibideen jarraipena:** hizkuntza naturalean zehaztutako zeregin konplexuen exekuzio fidela.
- **Testuinguruko ikaskuntza (*in-context learning*):** zeregin berrietara egokitzea *prompt*-ean bertan sartutako adibide gutxi batzuetatik abiatuta, pisuen eguneratzerik gabe. [6].

2.1.5 Testu hutseko LLMen mugak

Gaitasun nabarmenak badituzte ere, testu hutsean oinarritutako LLM-ek garrantzizko muga estrukturalak dituzte:

- **Ikusizko itsutasuna:** ezin dituzte zuzenean irudiak, bideoak, diagramak edo eska-neatutako dokumentuak prozesatu. Edozein ikusizko informazio testu bihurtu behar da aldeztu aurretik, horrek dakarren maila ezberdinetako informazio galerarekin.
- **Haluzinazioak:** ereduak baieztapen faltsuak sor ditzake itxurazko zihurtasunez, eta fenomeno hori areagotu egiten da erantzunak benetako ikusizko informazioan ainguratzea eskatzen duenean [13].
- **Dokumentu aberatsen ulermen mugatua:** fakturek, inprimakiek, grafikoek eta taulek testua eta ikusizko egitura konbinatzen dituzte, eta hori ezin da osorik testu lauaren bidez transmititu.
- **Arrazoiketa espaziala:** irudietako objektuen arteko erlazio topologikoak eta metrikoak testu bidez zehaztasunez deskribatzeko zailak dira.

2.1.6 Ikusmen-modalitatea txertatzeko beharra

Ikusizko informazioa mundu errealean oinarrituko pertzepzio-kanal bat da. Balio praktikoko handiko aplikazioek (negozio-dokumentuen analisia, irudi bidezko laguntza medikoa, gida autonomoa, robotekin elkarreragin naturala) testu eta irudien gaineko ulermen eta arrazoimena egiteko gai diren sistemak eskatzen dituzte. Behar horiek MLLMen garapena bultzatu zuten, ordenagailu bidezko ikusmena eta hizkuntza-ereduak helburu orokorreko eredu bakar batean integratzen dituztenak [14].

2.2 Modalitate Anitzeko Hizkuntza-Eredu Erraldoiak

2.2.1 Definizioa eta Hizkuntza-Eredu Erraldoiekiko desberdintasunak

MLLM zentzumen-modalitate bat baino gehiagotan informazioa prozesatu eta sortzeko gai den adimen artifizialeko eredu bat da. Lan honen testuinguruan, testuaz gaindikoa modalitate nagusia irudia da, nahiz eta azken belaunaldiko MLLMak bideo eta audioetara zabal daitezkeen [15, 16].

Hizkuntza-Eredu Erraldok klasikoekiko funtsezko bereizketa irudiak sarrera gisa onartzeko gaitasunean datza. Hizkuntza-Eredu Erraldok batek token linguistikoen espazio diskretuan soilik jarduten duen bitartean, MLLM batek ikusizko edukiaren irudikapen jarraituak txertatzen ditu, eta horiek hizkuntza-ereduaren *embedding* espazioarekin proiektatu eta lerrokatu behar dira. Modalitate anitzeko lerrokatze hori MLLMen diseinuaren erroka nagusia eta azkenaldiko ikerketaren ardatz nagusia da [15, 14, 17].

2.2.2 MLLMen arkitektura orokorra

MLLM modernoek arkitektura hedatuena (*Unified Embedding Decoder Architecture*, edo kodetzaile bateratutako dekodetzaile arkitektura) hiru osagai nagusik osatzen dute: ikusmen-kodetzailea (*vision-encoder*), modalitate anitzeko proiektorea (*multimodal projector*) eta hizkuntza-eredu erraldoia (LLM) [15, 14, 18].

Ikusmen kodetzailea Ikusmen kodetzailea sarrerako irudia bektore-sekuentzia bihurtzeaz arduratzen den osagaia da. Osagai honen arkitektura nagusia *Vision Transformer* (ViT) da, Dosovitskiy et al.-ek aurkeztua [19]. ViT-ak irudia tamaina finkoko eskualde karratuetan banatzen du (normalean 14×14 edo 16×16 pixel), eskualde bakoitza dimentsio finkoko bektore batera proiektatzen du linealki, eta bektore-sekuentzia emaitzaren gainean Transformer estandar bat aplikatzen du, posizio-kodeketak gehituz.

MLLMen testuinguruan, ikusmen-kodetzailea normalean kontraste bidezko ikaskuntza-ren bidez aurrentrenatutako eredua da, irudi-testu pareen datu-multzo erraldioen gainean, hala nola CLIP [20]. CLIPek ikusmen-kodetzaile bat eta testu-kodetzaile bat batera aurrentrenatu zituen Internetetik bildutako 400 milioi irudi-deskribapen pareen gainean. Horrek ikusmen-kodetzaileari semantikoki aberatsak diren eta hizkuntza naturalarekin lerrokatuta dauden errepresentazioak ematen dizkio. Eredu berriagoetan, hala nola *InternVL3-n* [2], *InternViT-6B* erabiltzen da, 6.000 milioi parametroko ikusmen-kodetzailea, berariaz entrenatua, ikusizko errepresentazioen kalitatea maximizatzeko.

Sarrerako bereizmena, bestalde, faktore kritikoa da. Kodetzaile klasikoek 224×224 pixeleko bereizmen estatikoetan jarduten zuten, eta horrek testu fina edo bereizmen handiko xehetasunak ezagutzeko gaitasuna mugatzen du. Arkitektura modernoek bereizmen dinamikoko (*dynamic high-resolution*) estrategiak hartu dituzte, irudia teselatan (*tiles*) banatzen dutenak eta horietako bakoitza modu independentean prozesatzen dutenak, ondoren errepresentazioak kateatzeko [15, 21, 22].

Modalitate Anitzeko Proiektorea Modalitate anitzeko proiektorea ikusizko kodetzailearen dimentsioari dagokion ikusizko bektoreak LLM-aren *embedding* espaziora mapatzen dituen lerrokatze-modulua da. Honen dimentsioa desberdina izan daiteke. Irtenbiderik zabalduena bi geruzako Geruza Anitzeko Pertzeptroi (*Multi-Layer Perceptron*, MLP) bat da, aktibazio ez-linealarekin [14]. *LLaVA-1.5* [23] bezalako lanek erakutsi zuten MLP konektore guztiz konektatu hau, harrigarria izan arren, eraginkorra dela datuetan, eta hainbat proba-bankutan *Perceiver Resampler*-ean oinarritutako irtenbide konplexuagoak gaintitzen dituela [24].

Eredu aurreratu batzuek proiektore-modulu sofistikatuagoak erabiltzen dituzte, ikusmen tokenen kopurua murrizteko eta kostu konputazionala kontrolatzeko azpilaginketa-mekanismoekin. Arkitektura gurutzatuan (*cross-attention*), Flamingo-k [15, 24] sartutakoa kasu, ikusmen tokenak LLM-an integratzen dira autoarretako geruzekin tartekatutako arreta gurutzatuko geruzen bidez, sarrera-token gisa zuzenean kateatu beharrean.

Hizkuntza-Eredutik Erraldoia (LLM) Hirugarren osagaia Hizkuntza-Eredutik Erraldoia da, sistemaren bizkarrezur gisa jarduten duena. Normalean, aurrez entrenatutako eta argibide-tara egokitutako LLM batetik abiatzen da [15, 11]. Proiektatutako ikusmen-tokenen eta testu-tokenen sekuentzia kateatua jasotzean, LLM-ak erantzuna modu autoerregresiboan sortzen du. LLM-a izoztuta mantendu daiteke modalitate anitzeko entrenamenduan zehar, bere testu-gaitasunak gordetzeko, eta partzialki edo izozketa guztiz kendu daiteke doikuntza fin gainbegiratuan (*Soft Fine Tuning*, *SFT*) [25].

2.2.3 Irudi-Testu Prozesamenduaren Fluxua

Dekodetzaile arkitektura bateratua duen MLLM baten prozesamendu-fluxua urrats hauek jarraituz deskriba daiteke [14, 15]:

1. Sarrerako irudia bereizmen finkoko eskualdetan banatzen da.
2. Ikusmen-kodetzaileak (ViT) eskualde bakoitza prozesatzen du eta ezaugarri-bektoreen sekuentzia bat sortzen du.
3. Modalitate anitzeko proiektoreak bektore horiek LLMaren *embedding* espaziora eraldatzen ditu.
4. Ondoriozko ikusmen *embedding*ak erabiltzailearen *prompt*-eko testu tokenen *embedding*ekin kateatzen dira.
5. LLMak modalitate anitzeko sekuentzia kateatua prozesatzen du bere autoarreta geruzen bidez, eta testu-erantzuna modu autoerregresiboan sortzen du, tokenetik tokenera.

Fluxu honek LLMari ikusizko edukia eta testua batera arrazoitze aukera ematen dio, biak sekuentzia linguistiko bereko parte balira bezala. Horrek testu-gaitasunak modalitate anitzeko domeinura transferitzea errazten du [14, 16].

2.2.4 MLLMen zeregin nagusiak

MLLMak helburu orokorreko ereduak dira, ikusmena eta hizkuntza konbinatzen dituzten hainbat zeregin hiltzeko gai direnak.

Ikusizko Galderen Erantzutea (VQA) Ikusizko Galderen Erantzutea (*Visual Question Answering*, VQA): irudi baten edukiari buruzko galdera naturalak erantzutean datza. MLLM gehiengoaren proba-banku-en ebaluazio-zeregin nagusia da, hala nola VQVA_{v2}, TextVQA eta RealWorldQA [15, 26]. MLLMek erakutsi dute VQA gaitasunak, erreferentziatzeko proba-banku anitzetan proba-banku horiek egin dituzten enpresen ereduaren errendimendua lortu edo gainditzen dutenak.

Karaktereen Ezagutza Optikoa (OCR) Karaktereen Ezagutza Optikoa (*Optical Character Recognition*, OCR) irudietan dagoen testua detektatzeko eta transkribatzeko gaitasuna da. MLLM modernoek OCRn gaitasun aurreratuak erakutsi dituzte, bai eszenako testuan (*scene text*) bai dokumentu egituratuetan, OCRBench bezalako proba-banku espezifikoekin ebaluatuz [15, 27]. Bereizmen handiko prozesamenduaren diseinua bereziki garrantzitsua da zeregin honetarako, testu-karaktere txikiek sarrera bereizmen handiak behar baitituzte.

Dokumentuen Ulermena Dokumentuen ulermenak (*document understanding*) dokumentu egituratuetan informazioa erauztea eta arrazoitzea barne hartzen du (fakturak, inprimakiak, kontratuak, artikulu zientifikoak eta taulak). DocVQA proba-bankua [28] zeregin honen erreferentzia estandarra da. Egungo MLLM onenek %94tik gorako puntuazioak lortzen dituzte DocVQAn, giza-mailatik hurbil dagoen maila lortuz dokumentu tipifikatuetan [15].

Grafikoak eta diagramak ulertzea Grafiko estatistikoek, fluxu-diagramek eta irudi zientifikoek ikusizko adierazpenak konbinatzen dituzte testu eta zenbakizko informazioarekin. ChartQA [29] eta AI2D [30] proba-bankuek ereduak eduki mota horri buruzko galderak erantzuteko duten gaitasuna ebaluatzen dute. Azken belaunaldiko MLLMek %94tik gorako emaitzak lortzen dituzte AI2Dn, ikusizko diagrama konplexuen ulermen sendoa isolatuz [15].

Modalitate anitzeko arrazoibidea Modalitate anitzeko arrazoibideak ikusizko eta testuzko informazioa integratzea dakar, inferentzia, logika edo munduaren ezagutza eskatzen duten problemak ebazteko. MMMU (*Massive Multidisciplinary Multimodal Understanding*) [31] proba-bankuak unibertsitate-mailako arrazoibidea ebaluatzen du zientzia, ingeniari, humanitateak eta artea bezalako disziplinetan. MathVistak [32] arrazoibide matematikoa-ren gaitasuna ebaluatzen du ikusizko testuinguruetan [15]. Datu-multzo horiek agerian utzi dute arrakala iraunkor bat dagoela kode irekiko ereduen eta jabetza pribatuko ereduen artean, nahiz eta arrakala hori pixkanaka murrizten ari den.

MLLMen egungo mugak Azkenaldiko aurrerapena bikaina izan arren, MLLMek zenbait muga garrantzitsu dituzte, ekoizpen-inguruneetan aplikagarritasuna baldintzatzen dutenak:

- **Ikusmen haluzinazioak:** ereduak irudiaren ikusizko edukiarekin bat ez datozen deskribapenak edo erantzunak sor ditzakete, *hallucination* edo ikusmen konfabulazio izeneko fenomenoak [15, 33].
- **Testu-errendimenduaren degradazioa:** modalitate anitzeko entrenamenduak azpiko LLMaren testu-gaitasunak degrada ditzake, *catastrophic forgetting* izeneko arazoa. Azken ikerketek, hala nola Ikusizko Lengoai Naturaleko Ereduak (*Natural Vision Language Model*, NVLM) erakutsi dute entrenamendu datuen konposizio arretatsu batek degradazio hori arindu edo irauli dezakeela [15].
- **Kostu konputazionala:** bereizmen handiko irudien prozesamenduak teselen bidez ikusmen-tokenen sekuentzia luzeak sortzen ditu, arretaren kostua koadratikoki handituz [15, 22].
- **Datuen kalitatea eta aniztasuna:** modalitate anitzeko entrenamendu datuen kalitatea eta aniztasun tematikoa bere eskala gordina baino erabakigarriagoa da [15].
- **Ikusmen pertzeptzio xehea:** objektu txikiak, testu txikiak eta espazio-harreman zehatzen ezagutza oraindik erronka irekia da egungo MLLMetan [21, 34].

2.3 Nola ebaluatu izan da arrazonamendu espaziala MLLMtan?

Modalitate Anitzeko Hizkuntza-Eredu Erraldioen (MLLM) aurrerapen azkarrak prozesu konplexuak neurtzeko gai diren proba-bankuak garatzeko beharra bultzatu du, objektuen ezagutza hutsetik haratago. Historikoki, hizkuntza naturalaren prozesamenduaren (NLP) eremuan, ARC-AGI [35] edo BIG-Bench [36] bezalako ebaluazioek eremua bultzatu dute, nahiz eta askotan azken erantzunaren zuzentasunaren menpe egon. Emaitzean oinarritutako ikuspegi horrek ereduak benetan arrazoitzen duen ala laburbide estatistikoak eta

azaleko heuristikak ustiatzen dituen ezkutatu ohi du [37]. MLLMen testuinguruan, arazo hau areagotu egiten da, bai testu-modalitateetan bai ikusizkoetan dauden alborapenengatik.

Datu-kutsadura [38, 39] bezalako arazoak arintzeko, komunitateak ebaluazio-prozedura edo paradigma sintetikoetara jo du [40]. Horiek zereginen parametroen gaineko kontrol fina ahalbidetzen dute. MLLMak ebaluatzean, arrazonamendu espazialaren eremua bereziki onuragarria da orokortze konposizionala ikertzeko. Informazio espaziala hizkuntza gizatiarrean zein mundu fisikoan nonahikoa denez [41], entitateak, haien harreman espazialak eta eraldaketak barne hartzen dituzten arazoak egituratzeak *ground truth* argia duten proba-eszenatokiak eraikitzea ahalbidetzen du.

Teorikoki, arrazonamendu espazialak norabideen, posizioen eta objektuen topologiaren ulermena barne hartzen ditu. Eskualdeen Konexio Kalkuluari (RCC) eta norabide-erlazioei buruzko oinarritzko lanek [42] oinarri formalak ematen dituzte MLLMek espazioa nola interpretatzen duten ebaluatzeko. Gaitasun hori funtsezkoa da eguneroko mundu fisikoa barneratzeko, Hayesek proposatutako "fisika inozoa" (*Naive Physics*) emulatuz [43]. Modalitate anitzeko sistemetan, horrek esan nahi du ez bakarrik harreman espazial-linguistikoak ulertzea, baizik eta ikusmen-espazioan behar bezala oinarritzea (*grounding*).

SCAN proba-bankua [44] bezalako lan aintzindariak hasiera batean jarraibideen itzulpena ekintza-kateetara ebaluatu zuten. MLLMetarako funtsezkoa izan zen gSCANerako bilakaera [45], datu-multzo hori bi dimentsiotako sareetan ainguratuz. Ebaluazio horiek batez ere sistematikotasuna probatu zuten: ereduak osagai ezagunak inoiz ikusi gabeko ikusizko eta testuzko konbinazioetan interpretatzeko duen gaitasuna. Ondorengo ikerketek [46, 47] arreta produktibitate bideratu ziren, jauzi anitzeko inferentzia erlazionala ebaluatuz (*multi-hop*), non ereduak hainbat adierazpen espazial kateatu behar dituzten eszena bateko objektuen antolamendua ondorioztatzen.

Hala ere MLLMetan benetako ulermena lortzeko, ezinbestekoa da konposizionaltasuna bere osotasunean ebaluatzea [48, 49]. Hupkes et al.-ek proposatutako esparruak [50] erakutsi zuen hori zuzenean hizkuntza naturalean ebaluatzea konplexua dela nahaste-faktoreengatik, PCFG SET bezalako alternatiba sintetikoak proposatuz. Deskonposatutako metodologia horietan inspiratuta, azken ikuspegiak, metodo neuro-sinbolikoetan oinarrituta [51, 52], aurrentrenatutako eredu handien malgutasuna logika probabilistikoaren sendotasunarekin konbinatzea bilatzen dute [53].

Beraz, MLLMetan arrazonamendu espazialaren ebaluazioak LLMetarako DecompSR paradigma bezala *zero-shot* edo *few-shot* konfigurazioetan jarduten duten tresnak behar ditu. Helburua da modalitate anitzeko aurrentrenamenduan eskuratutako gaitasun konposizional intrintsekoak (sistematikotasuna, produktibitatea eta konposizionaltasuna) diagnostikatzea, ereduak mundu errealean egitura espaziala ulertzen duela ziurtatuz, eta ez patroi korrelazional abstraktuak bakarrik.

2.4 Lan honetan erabilitako ereduak

Atal honetan, lan esperimentalean erabilitako hiru MLLMak deskribatzen dira. Kode irekiko ereduak dira, eta argitaratutako pisuak dituzte. Horri esker, konputazio-ingurune konbentzionaletan exekutatu daitezke, eta esperimentuen erreproduzigarritasuna errazten da.

2.4.1 Qwen3.5-9B

Jatorria eta familia *Qwen3.5* seriea Alibaba Group-eko *Qwen* taldeak garatutako oinarritzko ereduen bilakaeraren gailurra da [1]. Belaunaldi hau ulertzeko beharrezkoa da bere oinarritzko eredua aztertzea: *Qwen* familia hizkuntza-eredu gisa hasi zen (testuan soilik zentratuta), irudiak prozesatzeko kanpoko egokigailuak behar zituztenak (arkitektura modularra, hala nola, *Qwen-VL*).

Qwen3 serietik aurrera, paradigma aldatu egin zen, eta oinarritzko eredu bat sortu zen, datu mistoekin (testua, kodea, matematika arazoak, irudiak eta bideoa) eskala handian aurrentzenatuta. *Qwen 3.5*-ek oinarri hori hartu eta agentzia-sistemak garatzeko optimizatzen du bereziki (modu autonomoan arazoitzeko eta jarduteko gai diren sistemak).

Familia honen barruan, Adituen Nahasketa (*Mixture of Experts* MoE) erabiltzen duten eredu masiboak daude, ia 400 mila milioi parametro dituztenak, baita eredu trinkoagoak ere. Lan honetan, *Qwen3.5-9B* aldaera erabiltzen da, bederatzi mila milioi parametroko eredu trinkoa, modalitate anitzeko teknologiaren sarbidea demokratizazen duena. Gainera, aurreko ereduengan ikusi ez den errendimendua eskaintzen du, hardware lokal eta eskuragarrian.

Arkitektura *Qwen3.5-9B*-ren jauzi tekniko garrantzitsuena Transformer diseinu tradizionala uztea da, *Qwen3-Next* arkitektura-esparruarekin alderatuta. Esparru hori oinarri tekniko hauen gainean erakikitzen da [1]:

- **Arreta Hibridoa (Gated DeltaNet):** Testu luzeetan memoria-kontsumo esponentzialaren arazoa konpontzeko, ereduak arreta estandarreko geruzak eta Delta Sare Kontrolatuak (Gated Delta Networks) txandakatzen ditu. Arreta linealaren aldaera honek testuingurua modu oso eraginkorrean eskalatzea ahalbidetzen du, milioi bat tokeneko leihoak onartuz hardwarea kolapsatu gabe.
- **Modalitate Anitzeko Fusio Goiztiarra (Early Fusion):** *Qwen3.5*-ek ez ditu modulu bereziak erabiltzen ikusmen eta testurako. Bizkarrezur bakarra erabiltzen du, non ikusmen- eta testu-tokenak nahastu eta batera prozesatzen diren sarearen lehen geruzetatik, espazio- eta semantika-ulermen natiboa lortuz.
- **Eraginkortasun Handiko Tokenizatzailerak:** Hiztegi estrukturala 250.000 tokenera zabaldu da. Horrek konpresio-tasa nabarmen handitzen du, ingelesez ez diren hizkuntzetan eta programazio-lengoaletan testua irakurtzea eta sortzea azkartuz.
- **Token Anitzeko Iragarpena eta FP8 Zehaztasuna:** Arkitekturak token anitz aldi berean iragartzeko gaitasuna du, eta zehaztasun baxuan (FP8) funtzionatzeko optimizatuta dago geruza sentikorretan, latentzia eta aktibazio-memoriaren kontsumoa nabarmen murriztuz.

Gaitasunak eta errendimendua Fusio goiztiarreko arkitekturari eta oinarri-entrenamendu zorrotzari esker, *Qwen3.5-9B*-k agentzia-sistemak (*agentic workflows*) garatzeko duen joera nabarmentzen da. Chatbot sinple batek ez bezala, ereduak berezko gaitasunak ditu urrats anitzeko plangintzarako, arazoibide logiko konplexurako eta kanpoko tresnak deitzeko (kodea erabiltzea, web-bilaketa) [1].

Bere gaitasun nagusiak hauek dira:

- **Ikusmen-arrazoibide aurreratua:** Dokumentuen ulermen sakona, karaktereen ezagutza optikoa (OCR) trinkoa, analisi espaziala eta bideoen eta erabiltzaile-interfaze grafikoen (GUI) interpretazioa.
- **Eleaniztasun zabaldua:** 201 hizkuntza eta dialektorentzako euskarri sendoa eta eraginkorra, aurreko belaunaldien alborapen anglozentrikoa gaindituz.
- **Lan-fluxuen automatizazioa:** Bere diseinuari esker, laguntzaile digital autonomoen "garun" gisa integratu daiteke, ikusizko eta testuzko modalitateak konbinatuz ingurune errealetan ekintzak egiteko.

2.4.2 InternVL3.5-8B

Jatorria eta familia *InternVL3_5* Shanghai AI Laboratory-ko *InternVL* Team-ek garaturako seriearen azken iterazioa da, osorik kode irekian argitaratua [2]. Familiak tamaina sorta zabala eskaintzen du mila milioi parametrotako eredu trinko konpaktuetatik hasi eta 241 mila milioi parametrotako Adituen Nahasketako (MoE) arkitektura masiboetaraino. Lan honetan *InternVL3_5-8B* aldaera aztertuko dugu, tamaina ertaineko eredu trinkoa.

Arkitektura Arkitekturak ViT-MLP-LLM diseinu modularren paradigma mantentzen du. Sistema ikusmen-kodetzaile batek osatzen du, *InternViT-300M*-rekin hasieratuta aldaera eraginkorretarako, MLP proiektore modulu baten bidez *Qwen3* seriearekin hasieratutako hizkuntza-eredu bati konektatuta [2]. Prozesamendu eraginkorrerako, *Dynamic High Resolution* estrategia txertatzen du, irudiak bereizmen handian aztertzeko aukera ematen duena, bere alderdi erlazioari dinamikoki egokituz.

Diseinu estrukturalari dagokionez, ikusizko informazioaren fluxuak konpresio espazial zorrotzaren prozesu bat jarraitzen du bere tarteko geruzetan. Hasieran, ikusizko kodetzaileak irudiaren eskualde bakoitza prozesatzen du, 1024 ikusmen tokenen irudikapena sortuz. Ondoren, token horiek proiektore-modulua zeharkatzen dute, barnean *Pixel Shuffle* geruza gisa implementatuta dagoena. Honek 1024 tokenak 256 tokenetara konprimitzen ditu hizkuntza-eredura transferitu aurretik.

Berrentrenamendua hiru etapa nagusitan egituratzen da:

1. **Doikuntza Fin Gainbegiratua (SFT):** Kalitate handiko modalitate anitzeko datuak erabiltzen ditu arrazoiketa esplizitua (pentsamendu modua) eta interfaze grafikoekin interakzioa (GUI) gaitzeko.
2. **Cascade Reinforcement Learning (Cascade RL)** Bi fasetako errefortzu bidezko ikaskuntza-markoa ezartzen du. *Offline* fase batekin hasten da, *Mixed Preference Optimization* (MPO)-n oinarrituta, beroketa egonkorra ziurtatzeko, eta *online* fase batekin jarraitzen du, GSPO-n oinarrituta, irteera-banaketa iteratiboki fintzeko.
3. **Visuak Consistency Learning (ViCO):** Ikusmen kontsistentziaren ikaskuntza aplikatzen du, ikusmen-ebazpenaren bideratzailea (ViR) integratzeko, eta horrek token kopurua optimizatzen du aldaera eraginkorretan, hala nola *InternVL3.5-Flash* [2].

Gaitasunak eta errendimendua Ebaluazioen arabera, *InternVL3.5-8B* aldaerak 73.4ko puntuazioa lortzen du MMMU proba-bankuan. Ulermen-metrika horretatik haratago, seriearen aurreko belaunaldiak alderatuta, arrazoibide konbinatuaren errendimendu orokorra %16raino handituz eta inferentzia-abiadura $4.05 \times$ faktoreaz azkartuz.

Aplikazio praktikoei dagokionez, arkitekturak euskarri natiboa sartzen du zeregin konplexuak ebazteko, eta espresuki nabarmentzen du erabiltzaile-interfaze grafikoekin (GUI) elkarreragiteko eta gorputz fisikoa duten agenteen (humanoide edo beso robotikoak) eragiketak egiteko duen gaitasuna (*embodied agency*). Era berean, baliabideen optimizazioari dagokionez, probek dokumentatzen dute bere aldaera homologoaren (*InternVL3.5-Flash*) konpresio-mekanismoak prozesatutako ikusmen tokenen kopurua 50 murriztea ahalbidetzen duela, oinarritzko ereduaren errendimenduaren ia %100a mantenduz [2].

2.4.3 Gemma-4-E4B-it

Jatorria eta familia *Gemma-4* Google DeepMind-en adimen artifizialeko eredu irekien belaunaldi berriena da, *Gemini-3* eredu sortzaileetan erabilitako ikerketa- eta teknologia-oinarri beraren gainean eraikita [3]. Familia *Apache 2.0* lizentzia komertzialki permisiboaren pean banatzen da eta hiru eskalatan egituratuta dago, hardware-arkitektura desberdinak barne hartzeko: eredu trinko masiboak (31B Dense), aditu-nahasketa arkitekturak (26B MoE) eta ertz konputazionalerako ereduak (Effective 2B eta Effective 4B). Lan hone-tan, *Gemma-4-E4B-it* aldaera ebaluatzen da, IoT plataformetan eta gailu mugikorretan funtzionatzeko diseinatutako eredua.

Arkitektura E4B aldaeraren arkitektura berariaz diseinatuta dago konputazio- eta memoria-eraginkortasuna optimizatzeko. Sistemak lau mila milioi parametro eraginkor (Effective 4B) aktibatzen dituen aztarna konputazional batekin funtzionatzen du inferentzia fasean, eta horrek RAM memoria-kontsumoa minimizatzea eta tokiko hedapenetan bateriaren bizitza erabilgarria mantentzea ahalbidetzen du [3].

Prozesamendu-mailan, ereduak jatorrizko modalitate anitzeko arkitektura bat erabiltzen du, testua, irudiak, bideoa (bereizmen aldakorrek onartuz) eta soinua ezagutzeko eta ulertzeko jatorrizko audio-sarrera prozesatzeko gaitasunarekin. Epe laburreko informazioa atxikitze eta aztertze, familia honetako ertz-ereduek 128.000 tokeneko testuinguru-leiho zabal bat kudeatzen dute, dokumentu luzeak edo kode-baseak eskaera bakar batean prozesatzeko aukera emanez. Gainera, oinarritzko sarea jatorriz 140 hizkuntza baino gehiagotan entrenatu da.

Gaitasunak eta errendimendua *Gemma-4-E4B-it* familiaren arrazoibide aurreratua guztiz lokala eta offline den exekuzio ingurune batera eramaten du. Ia zero-latentzia-rekin funtzionatuz telefono adimendunak, ARM arkitekturak (Raspberry Pi) eta NVIDIA Jetson Orin Nano bezalako azeleragailuak bezalako hardware perimetralean [3].

Ereduaren diseinuak egiturazko euskarria barne hartzen du agentzia-eragiketarako (*agentic workflows*), funtzio-deiak (*function-calling*), JSON formatuko irteera egituratuak eta sistema-instrukzio natiboen prozesamendua integratuz. Eragiketa-malgutasunari dagokionez, aldaerak errendimendu handia erakusten du kodea sortzeko zereginetan, baita karaktereen ezagutza optikoan (OCR) eta grafiko eta diagramen interpretazio analitikoak bezalako ikusmen-zeregin kritikoetan ere.

Modalitate Anitzeko DecompSR datu-multzoa

3.1 Sarrera

Lan hau *DecompSR: A dataset for decomposed analyses of compositional multihop spatial reasoning* [54], hizkuntza-ereduetan arrazoitze espazial konposizionalerako gaitasunak ebaluatzeko berariaz diseinatutako proba-bankuan oinarritzen da. Nagusiki gainazaleko zehaztasunean edo informazioaren berreskurapenean zentratutako beste datu-multzo batzuek ez bezala, DecompSR-k ingurune kontrolatu bat proposatzen du, non posible den ereduaren inferentziaren arrazoibideari eragiten dizkieten hainbat faktore sistematikoki aldatzea.

Datu-multzo honen helburu nagusia arrazonamendu espaziala neurtzea da. Konkreteki, pauso anizkoitzeko arrazoiketa (ingelesez multi-hop reasoning) eskatzen duten arazo espazialak planteatzen dira. Arrazonamendu mota hau bereziki garrantzitsua da Hizkuntza-Eredu Erraldoi-en (ingelesezko LLM, Large Language Model) munduan, ereduak ze puntutaraino barne errepresentazio kontsistenteak eraikitze eta problemaren konplexutasuna handitu ahal inferentzia kate luzeak mantentzeko ahaltsuak diren aztertzea ahalbidetzen baitu.

Paper originaleko datu-multzoa soilik testuzkoa izan arren, lan honetan ez dugu erabiltzen DecompSR testuzko proba-banku bezala soilik, baizik eta modalitate anitzeko ingurune experimental baten eraikuntzaren oinarri bezala ere. Zehazki, datu-multzoko testuzko instantzia bakoitzera lotutako ikusizko diagramak automatikoki sortzen dituen kode bat garatu dugu, modu honetan hiru konfigurazio desberdinen pean ereduaren jarrera ebaluatu eta konparatzea ahalbidetuz:

- Testuzko sarrera.
- Irudizko sarrera.
- Testuzko eta irudizko modalitate anitzeko sarrera.

Irudizkoa edo modalitate anitzekoa den hedapen horren atzean dagoen motibazio nagusia honakoa da: gizakiek errazago ebatzen dituzte espazio-zereginak ikusizko irudikapenak dituztenean. Hau da, arazoaren erlazio espazialak laburbiltzen dituen diagrama edo irudi bat dagoenean, zeregina askoz sinpleagoa bihurtzen da. Inbolukratuta dauden erlazio eta entitate kantitatea handitzen den heinean, soilik testuzkoa den errepresentazioak karga nabarmen handiagoa sartzen du, grafo bidezko errepresentazio egituratu batek konexio garrantzitsuak askoz era intuitiboago batean identifikatzea ahalbidetzen duen bitartean.

Beraz, lan honen helburu zentraletako bat, gizakien antzera, ea gaur egungo modalitate anitzeko ereduak mota honetako errepresentazioetatik baliatzeko ahaltsuak diren analizatzea da, bereziki arrazonomendu konposizional sakon eta inferentzia konplexuko egoeretan.

3.2 Datu-multzoa: DecompSR

DecompSR datu-multzoko adibide bakoitzaren hiruko garrantzitsuena honakoa da:

$$\langle d, q, a \rangle$$

non:

- d -k (data) entitateen arteko erlazio espazialak deskribatzen dituzten esaldi anitzez konposatutako historia errepresentatzen duen,
- q -k (question) bi entitate zehatzen arteko erlazio espazialari buruzko galdera errerepresentatzen duen,
- a -k (answer) norabide espazial moduan adierazitako erantzun zuzena errerepresentatzen duen.

Horrez gain, beste informazio hau ere ematen digu datu bakoitzak:

- ID -k datu-instantzia bakoitzaren identifikatzaile bakarra errerepresentatzen du.
- $original$ -ek entitate bakoitzaren koordenatu espazialen mapa errerepresentatzen du (adibidez, "XAL": $[\emptyset, \emptyset]$).
- $nhop$ -ek jauzi kopurua adierazten du.
- $clean$ -ek adibide garbia edo zaratatsua den adierazten du.
- $shuffled$ -ek historiako enuntziatuen ordena ausaz nahasi den ala ez adierazten du.

Erlazio espazial posibleak, zortzi norabide hauen multzoaren barruan daude:

- above (gainean)
- below (azpian)
- left (ezkerrean)

- right (eskuinean)
- upper-left (goi-ezkerrean)
- upper-right (goi-eskuinean)
- lower-left (behe-ezkerrean)
- lower-right (behe-eskuinean)

Historiako esaldi bakoitzak bi entitatek bi dimentsiotako plano baten gainean daukaten elkarren arteko posizio erlatiboa deskribatzen du. Galdera erantzutzeko, normalean zuzenean konektatuta agertzen ez diren bi entitatereen arteko erlazio espaziala ondorioztatu behar da, eta ereduak hainbat inferentzia-urrats kateatu behar ditu.

Datu instantzia baten adibide bat ondorengoa da:

```
{ "ID": "50gZuxLq",
  "data": "1 XIC is placed on the top of XAL.\n",
  "question": "What is the relation of the agent XIC to the agent XAL?",
  "answer": "above",
  "original": { "XAL": [0, 0], "XIC": [0, 1], "XCP": "pseudo_coordinate" },
  "nhop": 1,
  "clean": true,
  "shuffled": false }
```



3.1 Irudia: Datu instantzia baten adibide sinplea

Kasu honetan, erantzuna esaldi bakarretik deduzitu dezakegu. Hala ere, arazoaren konplexutasuna handitzen den heinean, erantzunak tarteko harreman ugari konbinatzea eskatzen du.

3.3 Arrazonamendu sakonera (n-hop reasoning)

DecompSR datu-multzoko funtsezko elementuetako bat *nhop* parametroa da, arrazonamendu sakonera edo inferentzia jauzien kantitatea ere deitua. Parametro honek ereduak ongi erantzuteko kateatu behar dituen erlazio espazialen kopuru minimoa kontrolatzen du. Modu honetan:

- $nhop = 1$ -ek zuzeneko arrazonamendua inplikatzeko du, ereduak ez du urrats bat baino gehiago behar, esaldi bakarrean ematen baita galdera erantzutzeko informazio guztia, ikusi 3.1 irudia
- $nhop$ -en balio altuek inferentzia kate luzeagoak eskatzen dituzte, 3.2 irudian ikus dezakegu k tamaina ezberdinetako irudiak

Adibidez, $nhop = 3$ duen datu-instantzia batek honelako inferentzia eskatuko luke:

A B-ren eskuinean dago
 B C-ren gainean dago
 C D-ren ezkerrean dago

Lan honetan erabilitako datu-multzoak ondorengo $nhop$ -en balioak hartzen ditu:

$$k \in \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 20, 50, 100\}$$

$nhop = 50$ eta $nhop = 100$ bezalako balio handiak edukitzeak arrazonamendu konpositional sakondun egoerapean ereduaren jarrera ebaluatzea ahalbidetzen du, non konsistentzia espaziala mantentzea askoz zailagoa bihurtzen den. Gainera, DecompsR datu-multzoak $nhop$ balioa arazoa konpontzeko behar den inferentziatzeko bidearen gutxienezko luzerari dagokiola bermatzen du. Hori bereziki garrantzitsua da, aurreko proba-bankuetan zeuden anbiguotasunak saihesten baititu, non bide alternatiboak edo zikloak egon zitezkeen, adibidearen benetako zailtasuna artifiziarki murrizten zituztenak.

3.4 Datu-multzo originaleko aldaerak

Jatorrizko datu-multzoak ereduaren arrazoiketari eragiten dioten hainbat faktore kontrolatzeko aukera ematen du. Horien artean, lan honetan erabilitako bi aldaera nabarmentzen dira bereziki:

- Garbitasuna (*clean*).
- Esaldien nahasketa (*shuffled*).


3.4.1 Adibide garbiak eta zaratsutsuak

Datu-multzoak adibide garbien (*clean*) eta zaratsutsuen (*noise*) arteko bereizmena egiten du.

Adibide garbietan, historian dauden esaldi guztiak beharrezkoak edo garrantzitsuak dira erantzuna behar bezala ondorioztatzeko.

Noise adibideetan, aldiz, espazioan baliozkoak diren, baina galdera nagusia ebazteko garrantziazirik ez duten esaldi gehigarriak gehitzen dira. Esaldi horiek erantzuna lortzeko behar den gutxienezko inferentzia-bidean parte hartzen ez duten nodoak eta aparteko erlazioak sartzen dituzte.

Adibidez:




3.2 Irudia: *nhop* balioen arabera inferentzia-sakonera. Zenbat eta *nhop* handiagoa, orduan eta nodo eta erlazio gehiago kateatu behar dira galdera erantzuteko.

A B-ren eskuinean dago
B C-ren gainean dago

Ondorengo garrantzia gabeko erlazioekin hedatu ahalko litzateke:

X Y-ren ezkerrean dago
T U-ren gainean dago



3.3 Irudia: Adibide garbi eta zaratatsuen arteko konparaketa.

Erlazio gehigarri horiek azpigrafo espazial baliodunak sortzen dituzte, baina galderari dagokionez deskonektatuta edo baliogabetuta daudenak, ikusi 3.3a eta 3.3b irudiak. Zarata sartzeak ereduak zenbateraino arrazoiatarako benetan garrantzitsua den informazioa identifikatzeko gai diren aztertze aukera ematen du.

3.4.2 Adibide nahasiak

Datu-multzoaren beste aldaera nagusietako bat historian esaldien testu-ordena aldatzea da. *Shuffled* bertsioetan, esaldiak jatorrizko sekuentziarekiko desordenatuta agertzen dira. Hala ere, arazoaren eduki semantikoak berdin-berdin dira. Honi esker, ereduak testuaren ordena linealaren mende ote dauden azter daiteke, haien inferentzia espazialak eraikitze. Lan honen testuinguruan, *shuffled* eta *non shuffled* adibideei lotutako ikusizko irudikapenak berdin-berdinak dira, nodoen posizio espazialak ez baitira aldatzen; erlazioak testuan deskribatuta agertzen diren ordena baino ez da aldatzen.

3.5 Erabilitako datu-multzoaren banaketa

Esperimentuak egiteko, lan honetan, DecompsR-ren bertsiorik txikiena erabili dugu, ondorengo banaketa duena:

- *nhop* balio bakoitzeko 200 proba (*test*) adibide
- *nhop* balio bakoitzeko 200 entrenamendu (*train*) adibide
- *nhop* balio bakoitzeko 16 balidazio (*val*) adibide

Konplexutasun inferentzialaren 13 maila (*nhop*) egonda eta lau aldaera nagusi egonda:

- *clean shuffled*

- *noise shuffled*
- *clean non shuffled*
- *noise non-shuffled*

Guztira: 21632 instantzia daude. Hala ere, artikuluko ofizialaren metodologia berdina jarraituz [54], ebaluazio esperimentuak *test* multzoaren gainean egingo dira soilik: 10400 instantziaz osatua. *nhop* maila desberdinen arteko banaketa orekatuak aukera ematen du ereduaren errendimenduak eskatutako sakonera inferentziala handitu ahala nola eboluzionatzen duen aztertzeke.

3.6 Proposatutako modalitate anitzeko hedapena

Jatorrizko datu-multzoari egindako ekarpen nagusia testu-instantzia bakoitzerako ikusizko irudikapenak automatikoki sortzea da. Jatorrizko artikuluko diagrama argigarri batzuk dituen arren, DecompsSr-ek ez du proba-bankuaren modalitate anitzeko bertsio oso bat ematen. Beraz, lan honetan datu-multzoko instantzia guztietarako grafoen diagramak automatikoki sortzeko gai den kodea garatu dugu.

Irudi bakoitzak esplizituki adierazten du:

- Entitateak nodo gisa
- Harreman espazialak ertz gisa
- Entitateen kokapen espazial erreala bi dimentsiotan

Nodoak kokatzeko erabilitako koordenatuak ez ditugu artifizialki sortu, baizik eta jatorrizko datu-multzoan dauden entitateen kokapenaren informaziotik zuzenean lortu ditugu. Horrek, ikusizko diagramek testu arazoaren egitura espaziala errespetatzen dutela bermatzen du.

3.7 Diagramen sortze prozesua

Sortutako ikusizko irudikapenek grafoetan oinarritutako egitura jarraitzen dute, jatorrizko paper-ean aurkeztutako diagrama argigarrietan zuzenean oinarrituta [54].

Garrantzitsua da azpimarratzea, datu-multzoan guztira 21.632 instantzia egon arren, aldaera bakoitzeko 10.816 irudi bakarrik sortu direla. Hau horrela da, 3.4.2 atalean azaldu bezala, *shuffled* eta *non-shuffled* instantziek ikusizko irudikapen bera partekatzen dutelako (nodoen posizioak ez direlako aldatzen), eta beraz kopurua erdira murrizten da. Gainera, irudi horietatik 5200 erabiliko dira, *test* multzokoak soilik.

Taulan ikus daitekeen bezala (ikus 3.1 irudia), irudien bereizmena eta elementu grafikoaren tamaina ez dira finkoak; aitzitik, eskalatze espazial eta dinamiko bat aplikatzen da k (*nhop*) balioaren eta datuen baldintzaren (garbia edo zaratatsua) arabera. k balioak grafoaren konplexutasuna zehazten du: zenbat eta handiagoa izan k , orduan eta handiagoa izango da testutik erauzitako entitate (nodo) eta erlazio (arista) kopurua.

Irudi guztietarako bereizmen eta tamaina estatiko bat erabiliko balitz, bi ikusmen arazo nagusi sortuko lirateke: k txikia duten grafoetan nodo gutxi batzuk espazio handi batean balduta ikusiko lirateke; eta k handietan ($k = 50$ edo $k = 100$), berriz, gainjartze masiboa gertatuko litzateke, elementuek elkar zapalduz. Hori ekiditeko, irudiaren dimentsioak (bereizmena) handitu egiten dira k hazten denean, eta aldi berean nodoen tamaina, aristen lodiera eta letra-tipoa txikitu egiten dira. Horrez gain, *noise* (zarata) baldintzan nodo gehigarriak daudenez, bereizmen handiagoak esleitzen zaizkie elementu estrak sartu ahal izateko (adibidez, 1236×1228 pixel $k = 50$ *noise* kasuan, 864×859 pixel $k = 50$ *clean* kasuan erabili beharrean).

Matematikoki dena bereizmen finko batean proportzionalki txikitzea posible izango litzatekeen arren, muga fisiko bat dago: pixelen kopurua eta testuaren irakurgarritasuna. Bereizmen finko batean nodoak izugarri txikituko balira k handiko grafoetan, barruko testuak eta konexio-lerroak hain txikiak izango lirateke non pantailako pixelak ez liratekeen nahikoak izango haiek irudikatze (azpipixel bihurtuz eta irudia lausotuz). Horregatik, konplexutasun handiko kasuetan bereizmena handitzea ezinbestekoa da; horrela, pixel fisiko gehiago lortzen dira eta, nahiz eta nodoa irudiaren proportzioan txikia izan, bere barruko testua guztiz irakurgarria izaten jarraitzen du.

Azkenik, aipatu behar da eskalatze horren balio zehatzak (taulako bereizmenak, nodoen tamainak edo aristen lodierak) era heuristikoa eta enpirikoa zehaztu direla. Ez da formula matematiko itxi bat erabili; aitzitik, sareen ikusizko irudikapena optimizatzeko, k balio bakoitzeko grafikoen laginak ikusmen bidez aztertu dira doikuntzak eginez. Doikuntza enpiriko honen helburu bakarra, grafoen dentsitatea edozein dela ere, elementuen arteko gainjartzeak saihestea eta informazio guztia giza begiarentzat argia eta ulergarria dela bermatzea izan da.


Bereizmena (pixelak)	Irudi kopurua	Patroi adibideak (k balioak)
678×674	5.408 (% 50,0)	$k1, k2, k3, k4, k5, k6, k7, k8$
771×766	3.328 (% 30,8)	$k6, k7, k8, k9, k10, k20$ (<i>clean</i>)
1236×1228	416 (% 3,8)	$k50$ (<i>noise</i>)
957×951	416 (% 3,8)	$k20$ (<i>noise</i>)
864×859	416 (% 3,8)	$k50$ (<i>clean</i>)
2166×2152	416 (% 3,8)	$k100$ (<i>noise</i>)
1608×1598	416 (% 3,8)	$k100$ (<i>clean</i>)
Guztira	10.816 (% 100)	

3.1 Taula: Datu-multzoko irudien bereizmenen banaketa eta lotutako parametroak.

3.8 Sortutako ikusizko aldaerak

Ereduek bi arazo nagusi ebatzi behar dituzte ataza honetan: nodoen identifikazioa eta erlazio topologikoen arrazoiketa. Bi gaitasun horietan ereduek nola jokutzen duten aztertze, diagramen bi aldaera nagusi sortu ditugu, ikusizko laguntza maila desberdinekin.

"Erlazio" aldaera Aldaera honen helburua nodoen identifikazioa aurrez ematea da, ereduek erlazio topologikoen arrazoiketa modu isolatuan nola egiten duten aztertze. Horretarako, galderan inplikaturako bi entitateak urdinez nabarmentzen dira. Bi azpi-aldaera bereizi ditugu:



3.4 Irudia: Hiru ikusizko aldaeren arteko konparaketa adibide berean. Nodo urdinak galderako entitateak adierazten ditu; gezi urdinak erantzunaren norabide espaziala irudikatzen du.

- **Geziarekin:** nodo urdinen artean gezi urdin bat gehitzen da, erlazioaren norabide espaziala esplizituki adieraziz.
- **Gezirik gabe:** nodo garrantzitsuak urdinez markatzen dira, baina ez da erlazioaren norabide espazialari buruzko informazio espliziturik ematen.

Lehen azpi-aldaerak ikusizko laguntza handiena eskaintzen du, eta arrazoiketa espaziala zenbateraino erraztu daitekeen aztertzea du helburu. Bigarrenak, aldiz, laguntza partziala ematen du, erlazioaren inferentzia ereduaren esku utziz.

“Oinarrizko” aldaera Aldaera honetan nodo guztiak kolore berean irudikatzen dira, laranja. Konfigurazio honek ez du galderarekin lotutako entitateei buruzko pista espliziturik ematen, eta DecompSR-ren jatorrizko bertsioa erreproduzitzen du. Kasu honetan, ereduak bai nodoen identifikazioa bai erlazio topologikoen arrazoiketa egin behar dituzte. Horrela, historia osoan eta galderan agertzen diren nodo guztiek informazio maila bera dute, inolako ikusizko laguntza gehigarririk gabe.

3.4 irudian ikus ditzakegu hiru diagramak, atal honetan azaldutakoa errepresentatzen dutenak.

3.9 Sortutako testuzko aldaerak

Ikusizko aldaerez gain, testuzko errepresentazio desberdinak sortu ditugu baita ere (Ikusi [3.5](#) irudia, entitateen errepresentazio estrategia desberdinek erduen portaeran nola eragiten duten aztertze helburuarekin.

V1: jatorrizko izenak V1 bertsioak DecomPSR datu-multzoan dagoen jatorrizko testu-irudikapena mantentzen du.

Entitateen izenak aldaketarik gabe mantentzen dira, identifikatzaile abstraktuak erabiliz, honela:

XAL
XIC
XCP

Bertsio honek testuzko oinarri-lerro nagusi gisa jotatzen du.

```
{
  "ID": "0KVgUV95",
  "data": "1 XJR is sitting at the upper left position to XGD.\n
          2 XJT is above and to the right of XGD.\n
          3 XJT is positioned below XCJ and to the left.\n
          4 XCJ is to the top-left of XIR.\n",
  "question": "What is the relation of the agent XIR to the agent XJR?",
  "answer": "right",...
}
```

V2: entitateen mapaketa globala V2 bertsioak entitateen eta zenbakizko identifikatzaileen arteko korrespondentzien hiztegi global bat erabiltzen du.

Adibidez:

XAL(15)

Bertsio honetan, *XAL* nodoa agertzen den datu instantzia guztietan, 15 zenbakia izango du ondoan beti, eta bere ikusizko diagrametan nodoaren erdian bere entitate izen abstraktua agertu beharrean identifikazio zenbakia egongo da. Errepresentazio honen helburua, entitateen identifikatzaileen gainean egindako aldaketek ea erduen arrazoiketaren gaineko eragina daukaten aztertzea da. Erabateko ordezkapena ez bezala, erakundearen jatorrizko izena ere gordetzea erabaki dugu, jatorrizko datasetaren testu-egitura gehiegi ez aldatzeko eta konparagarritasun esperimental handiagoa izateko.

```
{
  "ID": "0KVgUV95",
  "data": "1 XJR(67) is sitting at the upper left position to XGD(43).\n
```



```

2 XJT(69) is above and to the right of XGD(43).\n
3 XJT(69) is positioned below XCJ(174) and to the left.\n
4 XCJ(174) is to the top-left of XIR(113).\n",
"question": "What is the relation of the agent XIR(113) to the agent XJR(67)?",
"answer": "right",...
}


```

V3: historia bakoitzeko zenbakitzea V3 bertsioa, V2 bertsioaren ia berdina da, baina zenbakitze estrategia guztiz aldatzen da. Bertsio honetan, historia indibidual (edo datu instantzia) desberdin bakoitzaren mendeko zenbakitze estrategia bat erabiliko dugu. Irudikapen honetan, inferentziazko bide nagusiari dagozkion nodoak lehenengo zenbakitzen dira, galdera ebazteko garrantzitsua den egiturazko ordenari jarraituz. Ondoren, zaratari lotutako nodo gehigarriak gehitzen dira, soilik *noise* motako datu instantzietan, noski. Modu honetan, zenbakien aukeraketak erabat arbitrarioa izateari uzten dio, eta erakundeek arazoaren barruan duten garrantzi erlatiboari buruzko informazio estrukturala partzialki txertatzen dugu. Errepresentazio mota honek, erregulartasun inplizitu batzuek ea modalitate anitzeko ereduen arrazoibidea erraztu dezaketen aztertze aukera ematen du.


```

{
  "ID": "0KVgUV95",
  "data": "1 XJR(5) is sitting at the upper left position to XGD(4).\n
2 XJT(3) is above and to the right of XGD(4).\n
3 XJT(3) is positioned below XCJ(2) and to the left.\n
4 XCJ(2) is to the top-left of XIR(1).\n",
  "question": "What is the relation of the agent XIR(1) to the agent XJR(5)?",
  "answer": "right",...
}


```



(a) V1 bertsioko grafo errepresentazioa: jatorrizko ize-nak.



(b) V2 bertsioko grafo errepresentazioa: mapaketa globaleko zenbakiak.



(c) V3 bertsioko grafo errepresentazioa: historia bakoitzeko zenbakitzea.

3.5 Irudia: Grafo errepresentazioen bilakaera: V1, V2 eta V3 bertsiok.

Diseinu Esperimentala eta Emaitzak

Kapitulu honetan, lanaren diseinu esperimentala eta lortutako emaitzak azaltzen dira. Zehazki, lehen atalean esperimentuen diseinua zehaztuko da, eta, ondoren, egindako esperimentuen emaitzak aurkeztu eta aztertuko dira.

4.1 Esperimentuen Diseinua

Lan hau egiteko burutu diren esperimentuentzarako kodeek oinarritzko egitura komun bat partekatzen dute. Horrek esperimentazio osoaren oinarria zehazten du. Erabilitako eredua, sarrera-modalitatea edo inferentzia-estrategia edozein dela ere, exekuzio-fluxua, sorkuntza-parametroak eta ebaluazio-sistema beti berberak dira. Homogeneotasun hau guk erabaki dugu, eta horrela, emaitzetan ikusitako edozein desberdintasun soilik kontrolatutako aldagai esperimentalei egotzi ahal izatea bermatzen dugu. Beraz, gure emaitzak ereduaren, modalitatearen eta *prompt*-a egiteko moduaren arabera dira, eta ez inplementazio inkosistentzien arabera.

4.1.1 Exekuzio ingurunea eta inferentzia motorra

Esperimentu guztiek vLLM erabili dute inferentzia motor gisa, eta haren gainean kargatzen dira ereduak, BFloat16 doitasunarekin. Datu mota hori aukeratu dugu, GPUaren memoria-kontsumoa nabarmen murrizten duelako FP32-aren aldean. Kasu guztietan, GPU-aren memoria ehuneko 90 -eko erabilerarekin konfiguratu dugu, sistema eragilearentzat eta CUDA driver-arentzat segurtasun-tarte bat utziz. Esperimentu guztietan, testuinguruaren gehienezko luzera 8.192 tokenetan finkatu dugu, eta balio horrek sarrerako *prompt*-a nahiz sortutako erantzuna hartzen ditu barne.

4.1.2 Emaitzen berregingarritasuna

Esperimentuen berregingarritasuna bermatzeko eta sorkuntza-prozesuko ausazkotasuna erabat ezabatzeko, dekodeketa zikoitza (*greedy decoding*) erabili dugu. Ezarpen honen

bidez, ereduaren gaitasun sortzailea blokeatzen da, agindu baten aurrean beti erantzunik gertagarriena hauta dezan. Zori-faktore oro alboratuz, exekuzio bakoitzean ereduak zehazki testu berbera sortuko duela bermatzen da, lortutako asmatze-tasak errealak direla eta esperimentua zehaztasunez errepika daitekeela ziurtatuz.

4.1.3 Datu-multzoa eta laginketa-protokoloa

Gure datu-multzoa JSONL formatuan gordetzen da, eta *streaming* moduan prozesatzen da, lerroz-lerro, alegia. Instantzia bakoitzari, zein azpimultzotan dagoen adierazten duen etiketa jarri diogu, entrenamendu multzokoentzat *train*, probakoentzat *test* eta balidaziokoentzat *val*. Gainera, datu instantzia bakoitzari, nodoen mapaketa hiztegia jarri diogu (V2 eta V3 testuzko aldaeren kasuan soilik) eta datu-multzoko diagramaren erreferentzia bidea. Ebaluaziorako, analisisa proba azpimultzora (*test*) soilik mugatu dugu, eta garbitzat markatutako (*clean*) nahiz ausaz nahasi gabeko (*non shuffled*) instantziak baino ez dira hautatzen. Irizpide hori ereduaren azken errendimendua testu-egitura estandarreko baldintzetan neurtzeko hartzen da, eta adibide nahasiek (*shuffled*) daukaten ausazko ordenatzeak eragiten dituen alterazio semantikorik gabe. Era berean, hautaketa horrek berez bermatzen du lagina ezin hobeto orekatuta egongo dela k konplexutasun-maila bakoitzeko. Horrela, ziurtatzem dugu kostu konputazionala mugatua dela eta esperimentu guztien artean konparagarria izango dela. Beraz, *test* multzoko 10.400 instantzietatik 2.600 erabiliko ditugu ebaluaziorako, k jauzi kopuru bakoitzeko 200.

4.1.4 Ebaluazio metrika

Asmatze-tasa (*accuracy*) hartu dugu ebaluazio metrika moduan. Ataza sailkapen itxi eta determinista izatean, ez dago asmatze partzialik, ereduaren iragarpena zortzi norabideetako batekin bat dator, edo okerra da. Gainera, norabide guztiek pisu logiko bera dutenez, asmatze-tasak modu zuzen eta intuitiboan islatzen du ereduaren arrazoitzeko ahalmena nola degradatzen den grafoko konplexutasunak (k balioak) gora egin ahala.

4.1.5 Inferentzia protokoloa

Kode batean ere ez da ereduari sartuko diogun sarrera (*system prompt*) bereizirik erabiltzen. Atazaren instrukzio guztiak erabiltzaile rolaren lehen eta txanda bakarrean txertatzen dira. Instrukzio-blokea estatikoa eta identikoa da esperimentu bereko lagin guztietarako, eta atazaren izaera adierazten du, baliozko zortzi erlazio espazialak esplizituki zerrendatuz. Erlazio espazial hauek erloju-esfera formatuko erreferentzietarako zein puntu kardinaletarako desanbiguazio-mapatzeak ematen ditu. Sarrera formatu agindu batekin ixten da, zeinak azken erantzunak ###Answer: forma hartzeak eskatzen baitu. Konbentzio horrek finkatzen du ondorengo erauzketa sistema. Bloke estatikoaren ondoren, instantzia bakoitzeko datu dinamikoak gehitzen dira, testu-historia eta galdera edo, irudiaren kasuan, irudia eta galdera. Erabilitako 0-shot *prompt* osoa [A.1](#) eranskinean ikus daiteke.

4.1.6 Post-prozesaketa eta ebaluazioa

Behin ereduaren irteera lortuta, lehenik eta behin, arrazonamendu blokea kentzen da, eredu batzuek azken emaitza eman aurretik, <think> etiketa artean eman dezaketena. Lortutako testuaren gainean hiru adierazpen erregularreko kaskada bat aplikatzen dugu, lehentasun ordena beherakorren:

1. **Patroi kanonikoa:** ###Answer:<etiketa> egitura zehatza bilatzen duen adierazpena.
2. **Markatzailearen aurreko etiketa:** Etiketa markatzailearen aurretik agertzen den kasua estaltzen duen adierazpena.
3. **Azken baliabidea (hitz gakoa falta denean):** Ereduak ### goiburua sortu baina Answer hitza kanpoan uzten duenean aplikatzen den adierazpena.

Patroi batek ere ez badu bat-etortzerik lortzen, iragarpena errore gisa erregistratzen da, hala, hutsegite kontrolatua bermatzen da, kodea eten gabe.

Erauzitako katea minuskuletara normalizatzen da, eta puntuazio-marka espurioak ezabatzen dira. Jarraian, baliokidetzak semantikoen hiztegi bat aplikatzen da. Hiztegi honen bidez, hizkuntza-ereduek erlazio diagonalak deskribatzeko erabili ohi dituzten adierazpen alternatiboak, datu-multzoaren hiztegi kanonikoarekin bateratzen dira:

- above right, right above → upper-right
- above left, left above → upper-left
- below right, right below → lower-right
- below left, left below → lower-left

Mapatze hori beharrezkoa da hizkuntza-ereduek erlazio diagonalak modu naturalean adierazteko joera dutelako, *above/below* hitzak ezkerre edo eskuinarekin konbinatzen dituztelako. Aldiz gure datu-multzoan, upper-/lower- aurrizkia erabiltzen dugu. Normalizazio hau gabe, espazialki zuzenak diren erantzunak txartat hartuko genituzke, eta beraz ereduak arrazoirik gabe penalizatuko genituzke. Azkenik, normalizatutako predikzioa eta instantzia horren erantzun zuzenaren arteko berdintasun zuzena neurtzen da, eta asmatze-tasa k bakoitzarekiko kalkulatu dugu. Honela, batez ere, ereduaren portaera neurtu dezakegu k parametroaren arabera.

4.1.7 Eredu bakoitzaren konfigurazioa

Esperimentu-logika, post-prozesatzea eta ebaluazioa guztiz komunak izan arren, ebaluatutako hiru ereduek desberdintasunak dituzte hasieratze- eta tokenizazio-geruzetan, eta horiek kasu bakoitzean berariazko egokitzapenak egitea eskatu digute. Desberdintasun horiek ez dira esperimentuaren diseinu-erabakien ondorio, kodearen funtzionamendu egokia bermatzeko ebatzi beharreko familia bakoitzaren berezitasunaren ondorio baizik.

Qwen3.5-9B: Eredu honek testuak eta irudiak tresna zentralizatu batetik kudeatzen ditu. Irtenbide bat eman aurretik arrazionamendu (*Thinking*) modua duenez, aukera hori desgaitu diogu esperimentu guztietan, *Thinking* modua ebaluatzeko esperimentuan ezik. Horrez gain, segurtasun handiagoa lortzeko, ereduak erantzunean sar zezakeen barne-pentsamenduaren edozein arrasto ezabatzeko ardura duen iragazki bat gehitu dugu. Bere tamaina dela eta, lan-karga bi txartel grafikoren (GPU) artean banatu behar izan dugu. Halaber, bateragarritasun-doikuntza bat aplikatu behar izan dugu proba konplexuenera edo ikusizkoenetan sistemak huts egin ez dezan.

InternVL3.5-8B: Hasierako prestakuntzarik ezohikoena izan duen eredua izan da. Sistemak testu barruan irudiak non hasten eta amaitzen diren behar bezala detekta dezan ziurtatzeko, irakurketa-osagai tradizionalago eta motelago bat erabili behar izan dugu, izan ere, modu lehenetsiko bertsio azkarrak ez ditu bereizketa hori egiteko beharrezkoak diren etiketak. Aurreko ereduak ez bezala ez dugu arrazoibide-gaitasuna kudeatu behar izan, ez baitu aukera hori jatorriz barne hartzen. *Qwen*-en antzeko tamaina izan arren, txartel grafiko bakarrean ezin hobeto funtzionatzea lortu du, ziurrenik bere memoriaren kudeaketa eraginkorrago bati esker.

Gemma-4-E4B-it *Qwen*-en antzekoa izan da honen prestakuntza. Testua eta irudiak ere batera kudeatzen ditu. Desberdintasun nabarmenena kalkulu-prozesu estandarrarekin erabat bateragarria dela erakutsi duela izan da. Beraz, ez du *Qwen*-en blokeoak saihesteko aplikatu ditugun aparteko segurtasun-partxerik behar izan. Txartel grafiko bakarrean exekutatu dugu hau ere. Oso eredu-familia astunekoa izan arren, adituen nahasketa (in-geleseko *Mixture of Experts* edo MoE) izeneko sistema erabiltzen du. Horrek esan nahi du bere ezagutza guztia aldi berean erabili beharrean, galdera bakoitzerako behar duen zati espezifikoak soilik aktibatu eta erabiltzen duela, eta horrek izugarri murrizten du haren memoria-kontsumoa.

4.1.8 Irudien prozesamendua ereduaren ebaluazioan

Lan honetan, modalitate anitzeko moduetako ereduaren barne-portaera aztertu da xehetasunez inferentzia-fasean, irudiak ereduak prozesatu aurretik nola eraldatzen diren ulertzeko helburuarekin. Prozesu hau kritikoa da, modalitate anitzeko moduetan (MLLM) "ikusmena" nola egiten den zehazten baitu xehetasun finen inguruan arrazoitze gaitasuna [16]. Hiru arkitektura desberdin alderatu dira: *Qwen3.5-9B* [1], *InternVL3.5-8B* [2] eta *Gemma-4-E4B-it* [3]. Horietako bakoitzerako, *image processor*-aren irteera aztertu da, baita irudi desberdinen ebazpenetatik eta k parametroaren balioetatik sortutako tentsoreen egitura ere.

Qwen3.5-9B

Qwen3.5-9B-ren kasuan, irudiaren aurreprozesamenduak sarrera bakoitza *pixel_values* multzo bihurtzen du, sarrerako ebazpenaren araberako forma aldakorrarekin. Teknika hau ohikoa da ikusmen-fideltasuna mantendu nahi duten ereduaren, informazioa galdu gabe eskalatze agresiboen bidez [21]. Zehazki:

- Irudiak (H' , W') formako tentsore bidimentsionaletara proiektatzen dira, non bi dimentsioak proportzionalki hazten diren.
- Balioen tartea $[-1, 1]$ tartean normalizatzen da.
- Lagin guztiek 1536ko bigarren dimentsio finkoa partekatzen dute, eta lehenengoa aldatu egiten da, ebazpen dinamikoaren kudeaketa iradokiz.

Portaera honek adierazten du ereduak *flattened visual embedding* motako irudikapen batekin lan egiten duela, non irudia ikusizko-tokenen sekuentzia luze bihurtzen den. Ikuspegi honek granularitate handiagoa ahalbidetzen du arrazoibide espazialeko zereginetan [54]. Gainera, *image_grid_thw* bezalako tentsore osagarrien presentziak kodetze espazial egituratuaren ideia indartzen du.

InternVL3.5-8B

InternVL3.5-8B ereduak *GotOcr2ImageProcessor* bat erabiltzen du, transformer bidezko ikusmenaren normalizazio estandarra ezartzen duena [19]:

- Irudi guztiak 448×448 tamainara birneurritzen dira, CLIP-like arkitekturetan eraginkortasuna eta zehaztasuna orekatzeko tamaina estandarra [20].
- ImageNet-en normalizazio estandarra aplikatzen da.
- Irteera (1, 3, 448, 448) formako tentsore finko bat da.

Diseinu honek prozesamendua sinplifikatzen du, baina, modalitate anitzeko moduetako OCRari buruzko literaturan eztabaidatu den bezala, errendimendua mugatu dezake testu oso txikia edo bereizmen handiko xehetasunak detektatzeko zereginetan, partizio-teknika gehigarriak erabiltzen ez bada [27, 28].

Gemma-4-E4B-it

Gemma-4-E4B-it-en kasuan, irudiaren prozesamendua modalitate anitzeko moduan integratzeko espezializazioagatik nabarmentzen da [3]:

- Irudia (1, 2520, 768) dimentsio finkoko ikusmen-tokenen sekuentzia bihurtzen da.
- Posizioen irudikapen esplizitua sartzen da `image_position_ids` bidez, sekuentzia luzeetan posizio-zehaztasuna hobetzeko rotary embeddings-en erabileraren antzera [8].

Ikuspegi honek tokenizazio espazial esplizituaren eskema iradokitzen du, testuzko eta ikusizko modalitateen arteko lerrokaduran koherentzia handiagoa bilatuz [25].

4.1.9 Ondorioa

Oro har, ereduak estrategia dibergenteak aurkezten dituzte, artearen egoera (*State of Art*) islatzen dutenak: batzuek ebazpen dinamikoaren malgutasunaren alde egiten duten bitartean (*Qwen3.5*), beste batzuek tamaina finko normalizatuen sendotasuna lehenesten dute (*InternVL3.5*) edo token posizionalen integrazio natiboa (*Gemma-4*). Diseinu-erabaki hauek eragin zuzena dute eraginkortasun konputazionalan, baina baita eszena konplexuak interpretatzean ereduak ikusizko haluzinazioak izateko joeran ere [33, 13].


4.2 Emaizak

4.2.1 Datu-multzoko errepresentazio aldaerak


Atal honetan, sarrerako informazioa adierazteko modu desberdinek ereduaren errendimenduan duten eragina aztertzen da. Helburu nagusia konfiguraziorik sendoena eta eragin-korrena zehaztea da, bai *prompting* estrategia zehazteko eta bai datu-multzoko testuzko errepresentazio aldaerak zehazteko. Behin zehaztuta, erabakiak hartu eta oinarritzat hartuko ditugu ondorengo esperimentuetarako.

Inferentzia-estrategiak: 0-shot vs 5-shot Testuzko errepresentazioen aldaeren eragina ebaluatu aurretik, *prompting* estrategia zuzena ezartzea beharrezkoa da. Horretarako, ereduak testuinguruko ikaskuntzaz baliatzen ote diren ebaluatu da, testu modalitateko bi konfigurazio konparatuz:


- **0-shot konfigurazioa:** Ereduak ataza prozesatzen du, sistemaren instrukzio orokorrean eta ebaluatu beharreko instantziaren datuetan (historia eta galdera) soilik oinarrituta. Ereduak instrukzioak jarraitzeko duen berezko gaitasunean bakarrik oinarritu behar du.
- **5-shot konfigurazioa:** Ebaluazio-instantzia aurkeztu aurretik, entrenamendu-multzotik erauzitako bost adibide ebatzi txertatzen dira elkarrizketaren historian. Adibide horiek erabiltzailearen eta ereduaren arteko elkarrizketako aurretiazko txanden forma hartzen dute. Konfigurazio honetan erabilitako mezu-sekuentzia osoa [A.2](#) eranskinen jasota dago.



(a) Qwen



(b) InternVL



(c) Gemma

4.1 Irudia: Hiru ereduaren errendimendu-kurbak bi konfigurazioetarako (0-shot vs. 5-shot).

Estrategia horien analisi enpirikoak (ikusi 3.1 Irudia) fenomeno kontraintuitibo bat erakusten du. Testuinguruan adibideak sartzeak (5-shot) ereduaren asmatze-tasa ez hobetzez gain, modu orokorrean zigortzen ditu *Qwen* eta *Gemma* ereduak k konplexutasun-maila espazialaren balio gehienetan.


Datuetara joz, 0-shot konfigurazioan *Qwen* ereduak, $k = 2$ denean, %85, 5eko asmatze-tasa lortzen badu ere 5-shot konfigurazioan balio hori %71ra jaisten da. *Gemma* ereduaren kasuan, degradazioa are nabarmenagoa da. $k = 2$ denean %59, 5etik %34ra erortzen da,

eta $k = 3$ denean, asmatze-tasa erdira murrizten da, %48tik %24,5era. *Qwen* eta *Gemma* erduetan, beste k -ren ia balio guztietarako 5-shot estrategia 0-shot strategiaren kurbaren azpitik mantentzen da, errendimendu eskazagoa erakutsiz. *InternVL* ereduak, bere aldetik, errendimendu oso antzekoa erakusten du bi konfigurazioetan, baina esan beharra dago ere, beste bi ereduak baino okerrago funtzionatzeko duela 0-shot estrategian. Hala ere, ez du 5-shot strategiaren adibideak gehitzearen inolako onura esanguratsurik erakusten.

Degradazio eta geldialdi horrek iradokitzen du testuinguruaren luzera nabarmen handitzeak zarata sartzen duela eta ereduak arreta galtzea eragiten duela. Horrela ataza orokortu beharrean, ereduak erakustaldi-adibidetako ibilbide topologiko espezifikoetara gehiegi doitzen dira. 5-shot konfigurazioak kostu konputazionala nabarmen handitzen duenez eta emaitzak okertzen (edo batere hobetzen ez) dituenenez, hura erabiltzea baztertzen da eta 0-shot prompting estrategia estandar gisa finkatzen da ondorengo esperimentu guztietarako.

Testuzko aldaeren analisia 0-shot estrategia finkatu ondoren, hiru testuzko aldaeren (V1, V2 eta V3) eragina ebaluatu dugu testu-modalitate hutsean, hiru erduentzako.

Dagozkien hiru grafikoen emaitzek (ikusi 4.2 irudia) entitateen jatorrizko izenak aldatzean inolako onurarik ez dagoela erakusten dute. *Qwen*en kasuan, V1, V2 eta V3 aldaeretakorako errendimendu-kurbak ia gainjarrita daude, eta jatorrizko aldaerak (V1) abantaila txiki bat edo berdintasuna mantentzen du inferentzia-jauzi ia guztietan (adibidez, %72ari eutsiz $k = 5$ denean, alternatibean %72aren eta %75aren aurrean).



4.2 Irudia: Hiru erduen errendimendu-kurbak testu-modalitateko aldaeretakorako (V1, V2, V3).


InternVL eta *Gemma*-ren kasuan, patroia identikoa da, eredu guztiek errendimenduaren degradazio larria jasaten dute k handitu ahala ($k = 5$ -etik aurrera %30etik behera jaitsiz). Gainera, mapatze globalak (V2) edo zenbakitze egituratuak (V3) txertatzeak ez du inola

4. DISEINU ESPERIMENTALA ETA EMAITZAK


ere lortzen beherakada hori arintzea. Izan ere, identifikatzaile abstraktuen ondoan zenbakiak txertatzeak tokenizatzaileari karga gehigarri bat gehitzen diola dirudi, testu lauaren formatuan ereduertarako balio semantiko ustiagarriak ekarri gabe.

Irudien gaineko testuzko aldaeren analisia Aldaera horiek berak irudi hutsaren modalitatean ebaluatzeak ondorio are erabakigarriagoak ematen ditu. Modalitate horretan, non informazio espaziala grafoen irudiaren tentsoreetan kodetuta transmititzen den, bertsiot egituratuak (V3) ereduaren ikusmen-arreta inferentzia-ibilbidean zehar gidatu ahal izatea espero genuen.


Hala ere, grafikoek (ikusi 4.3 irudia) kontrakoa erakusten dute. *Qwen* ereduaren, V3 aldaerak zigor drastikoa jasaten du konplexutasun-maila baxuenetatik hasita (hasieran %76, 5ekoa $k = 1$ denean, V1 aldaeraren %100-aren aurrean). V3rako zigortze-patroi bera ikusten da *InternVL*-n (non ia 20 puntu jaisten den V1-ekiko $k = 1$ denean). *Gemma* da ikusmen-aldaketekiko tolerantzia handiagoa erakusten duen eredu bakarra. Nolabaiteko parekotasuna erakusten du V1 eta V2 artean, baina irudiak aldatzea justifikatuko lukeen abantaila argi eta iraunkorrik agerian utzi gabe.



(a) Qwen



(b) InternVL



(c) Gemma

4.3 Irudia: Hiru ereduen errendimendu-kurbak ikusmen-modalitateko aldaeretak (V1, V2, V3).

Ikusmen-nodoen erdian zenbakiak egoteak, batez ere horien banaketa historiaren araberak dinamikoki aldatzen denean (V3), ikusmen-artefaktuak sartzen ditu; artefaktu horiek ikusmen-kodetzaileak grafo topologiko garbia erauzteko duen gaitasunarekin interferitzen dute, eta irudiaren nahiz testu-instrukzioaren arteko lerrokatzea nahasten dute.

Oinarrizko konfigurazioaren ondorioak Azaldutako datu esperimentalen argitan, frogatuta geratu da entitateen nomenklaturako aldaketek (V2 eta V3) ez dutela hobekuntza

nabarmenik ekartzen ereduaren arrazoibide espazialean, eta, ikusmen-modalitatearen kasuan, errendimendua gogor zigortzera irits daitezkeela.

Ondorioz, jatorrizko datu-multzoarekiko fideltasun handiena bermatzeko eta alborapenak nahiz alferrikako zarata sartzeari sahisteko, ondorengo esperimendu guztiak V1 aldaera (jatorrizko izenak) soilik erabiliz egingo dira *0-shot* inferentzia-konfigurazioaren pean.

4.2.2 Ikusizko eta testuzko errepresentazioen arteko konparaketa

Entitateen jatorrizko testuzko V1 aldaera finkatu ondoren, atal honek lanaren lehen galdera nagusiari heltzen dio. Ereduen arrazoibide espazialerako gaitasuna nola alderatzen den ebaluatzea, informazio topologikoa hizkuntza naturalaren bidez modu sekuentzialean emanda, grafo bidimentsional baten formako ikusizko irudikapenaren aurrean. Horretarako ereduaren asmatze-tasa neurtu da testuzko eta irudizko modalitateetan.


Ereduen araberrako analisi konparatiboa Lortutako hiru grafikoei (ikusi 4.4 irudia) portaera-patroi oso desberdinak erakusten dituzte eredu-familiaren arabera, baina ikusmen-modalitatearen eskalagarritasunari dagokionez egiturazko ondorio berera bideratzen dute.

Qwen3.5-9B. *qwen*-en portaera nabarmentzen da testu-modalitatean distantzia labur eta ertainetan duen ezohiko sendotasunagatik. Testu-formatuan, ereduak asmatze-tasa oso altua mantentzea lortzen du (%60tik gora) $k = 10$ denean ere, konplexutasun-tarte horretan ikusmen-modalitatea puntu jakin batzuetan gainditzeraino (adibidez, %81,5 testuan eta %69 irudian $k = 3$ denean). Hala ere, testuak sekuentzia lineal gisa duen berezko muga agerian geratzen da muturreko balioetan: $k = 50$ eta $k = 100$ balioetara iristean, ereduak testuan duen errendimendua erabat kolapsatzen du, %3,5era eta %5era jaitsiz (ausazko erantzunen azpitik). Aitzitik, irudi hutsaren modalitateak konplexutasunaren hazkundera modu ikaragarri egonkorrean xurgatzen du, sare trinkoenetan %47,5 – %51,5 inguruko errendimendua mantenduz.


InternVL3.5-8B eta Gemma-4-E4B-it. *InternVL* eta *Gemma*-ren kasuetan, testuaren eta irudiaren arteko arrakala drastikoa da konplexutasunaren lehen etapetatik. Testu hutsaren modalitatean, *InternVL*-k beherakada malkartsua jasaten du lehen inferentzia-jauziaren ondoren: $k = 1$ denean %83 izatetik $k = 2$ denean %36,5 izatera pasatzen da, eta pixkanaka degradatuz doa sare luzeetan %10 eta %15 artean finkatu arte. *Gemma*-k antzeko degradazioa erakusten du, $k = 6$ -tik aurrera %30-etik behera jaitsiz. Hala ere, ikusizko irudikapen hutsa txertatzean, bi ereduaren errendimendua errotik aldatzen da. Asmatze-tasaren kurbak beherakada esponentziala uzten du, eta marra ia horizontal bihurtzen da. *InternVL*-k bere errendimendua egonkortzen du espektroaren zatirik handienera %50 – %60 inguruan orbitatuz, $k = 100$ denean %40,5 nabarmena mantenduz. Era berean, *Gemma* %60 – %70eko tartean mantentzen da distantzia ertainetan, probatutako konplexutasun handienera %42ko zehaztasuna gordez.

Ondorioa: Ikusmenaren egiturazko egonkortasuna Konparazio honetatik ateratzen den mezua nagusia zalantzarik gabekoa da: irudien erabilerak arrazoibide-esparru askoz egonkorragoa eskaintzen du k konplexutasuna handitu ahala. Testu-modalitatean, ereduak erlazio-grafoa mentalki eraiki eta eguneratu behar du premisak sekuentzialki irakurri ahala. Jauzi kopurua (k) handitu ahala, kargak ereduaren ahalmena gainditzeko, haluzinazio


4. DISEINU ESPERIMENTALA ETA EMAITZAK



(a) Qwen



(b) InternVL



(c) Gemma

4.4 Irudia: Hiru ereduen errendimendu-kurbak: Testua vs Irudia (T1).

topologikoak eta errendimenduaren kolapsoa eraginez. Aitzitik, ikusmen-modalitateak egitura espazial globala zuzenean txertzen du ikusmen-kodetzailean urrats bakarrean. Ikusizko erlazioen hasierako erauzketa erronka izan daitekeen arren (*qwen*-ek k baxuetan jasaten duen beherakada arinean ikusten den bezala), irudikapen horrek grafoa bere lan-memoria sekuentzialean mantentzeko beharretik askatzen du eredua. Ondorioz, konplexutasun topologikoak botila-lepo izateari uzten dio. Horrela, dedukzio linguistiko hutsak porrot egiten duen ingurune espazial masiboetan ($k = \{50, 100\}$) errendimenduari eusteko aukera ematen die erreduei.

4.2.3 Ereduen portaera aztertzen ikusizko sarrerekin

Aurreko atalean frogatu da ikusmen-modalitateak egiturazko sendotasun handiagoa duela testu hutsaren aurrean, konplexutasun espaziala (k) handitu ahala. Hala ere, grafo bidentzional baten formako irudikapenen gainean arrazoibide espaziala ebaluatzeak erronka metodologiko garrantzitsu bat planteatzen du. Ikusizko ataza ebazteko, ereduak bi fasetako prozesu bat behar bezala exekutatu behar du.

Lehenik, ereduak ikusizko identifikazioa egin behar du (hainbat distrakzio nodoz betetako grafo baten barruan galdetzen diren bi nodo zehatzen bilaketa eta lokalizazioa). Bigarrenik, behin lokalizatuta, arrazoibide espaziala aplikatu behar du (haien arteko erlazio direkzional erlatiboa kalkulatzeko). Dualitate horrek alborapen bat sartzen du ebaluazioan. Baliteke eredu batek atazan porrot egitea, ez espazioari buruz arrazoitzeko ezintasunagatik, ingurune trinko batean entitate zuzenak lokalizatzen saiatzean haren ikusmen-arretan huts egiten duelako baizik. Benetako gaitasun espazialen bidezko ebaluazioa bermatzeko,

esperimentu honek identifikazio-fasean ereduari modu artifizialean laguntzen zaionean errendimendua nola aldatzen den aztertzen du.

Inpaktuaren analisisa eredu bakoitzeko Lortutako grafikoek (ikusi 4.5 irudia) agerian uzten dute ikusizko identifikazioaren karga arintzeak eragin zuzen eta positiboa duela ereduaren zehaztasunean. Horrek oinarritzko konfigurazioko akatsen zati bat ikusmen-arretaren botila-lepoen ondorio zirela erakusten du, eta ez hutsegite logikoenak.


Qwen3.5-9B Eredu honek ateratzen dio etekin handiena ikusmen-laguntzari. Gezirik gabeko aldaeran, haren errendimenduak hobekuntza nabarmena du jada oinarriarekiko, bereziki jauzi ertainetan (adibidez, %69tik %71,5era igoz $k = 3$ denean, eta %62tik %73,5era $k = 5$ denean). Hala ere, gezia sartzeak erabat desblokeatzen du haren gaitasuna: *qwen*-ek grafoaren konplexutasuna ia erabat xurgatzea lortzen du, bere emaitzak espektro ia osoan %75etik gora eskalatuz eta %67ko zehaztasun bikaina mantenduz $k = 100$ eko sare masiboetan (oinarrizko irudiaren %51,5aren aldean). Horrek erakusten du *qwen*-ek berezko norabide-gaitasun bikaina duela, laguntzarik gabe nodoak bilatzeko eskatzen zaionean nolabait ezkutuan geratzen dena.

InternVL3.5-8B *qwen*-en antzera, *InternVL*-k progresio mailakatua erakusten du. Nodoak koloreztatze hutsak gezirik gabe oinarritzko aldaeraren gainetik zertxobait egonkortzen du haren kurba. Gezia gehitzean, ereduak errendimendu-jauzi argi eta iraunkorra jasaten du, distantzia ertain gehienetan %60 eta %70 artean orbitatzera pasatuz eta %49,5 gordez probatutako konplexutasun handienera. Identifikazioa erraztuta, ereduak bere irudiaren tentsoreetan dagoen nodoen arteko posizio erlatiboa ebaluatzeko kontzentratzen ditu, norabide-asmatzeak hobetuz.


Gemma-4-E4B-it *Gemma*-ren kasuak ñabardura desberdinak ditu. Gezia duen aldaerak hasierako bultzada ematen dion arren (%78ra igoz $k = 2$ denean, oinarritzko %67,5aren aurrean), konplexutasun-balio altuenetan ($k = 50, 100$) hiru kurbak konbergitzera jotzen dute. Eredu honetan, gezirik gabeko aldaerak oinarritzko irudiaren oso paraleloa den errendimendua erakusten du. Horrek, haren ikusmen-arreta arkitekturak, nodoen bilaketa dentsitate baxu eta ertainetan berez ondo ebatzen duela iradokitzen du. Baina norabide aldetik saturatu egiten dela oso populatuta dauden grafoetan, ematen zaion laguntza edozein dela ere.

Ondorioa: Ikusizko bilaketaren botila-lepoa Esperimentu honetan bildutako datuek hipotesi nagusia balioztatzen dute: entitateen ikusizko identifikazioak botila-lepo funtsezko gisa dihardu nodo asko dituzten grafoen gaineko arrazoibidean. "Ikusizko bilaketaren" pisua ekuaziotik kentzen denean (nodoak nabarmenduz edo ibilbideak esplizituki marraztuz), ereduak berezko konfigurazioetan erakusten dutena baino arrazoibide espazialerako gaitasun handiagoa dutela frogatzen dute. Ondorioz, modalite-anitzeko eredu batek espazio bidimentsionala zenbateraino ulertzen duen erabateko bidezkoatasunez ebaluatzeko guk ez dizkiogu emango ikusizko pista horiek. Beste bi aldaerekin konparazioa eginez, emaitz txarragoak eman digun arren, testu arruntari dagokionez bidezkoena den aldaera erabiliko dugu, "oinarrizko" aldaera, gezirik gabe, eta galderan inbolukratutako nodoak koloreztatu gabe.


4. DISEINU ESPERIMENTALA ETA EMAITZAK



(a) Qwen



(b) InternVL



(c) Gemma

4.5 Irudia: Hiru ereduen errendimendu-kurbak: Irudi-motaren eragina (T2).

4.2.4 Modalite anitzeko sarrera-datuen azterketa

Aurreko esperimentuetan testu- eta irudi-aldaerak, bakoitza bere aldetik, ebaluatu dira, eta konplexutasun espazial (k) handiko grafoetan egonkortasun estrukturala mantentzeko ikusizko irudikapenaren nagusitasun argia frogatu dugu. Esperimentu honek ikuspegi hibrido baten ebaluazioari heltzen dio. Bertan, ereduari informazio-iturri biak aldi berean eskaintzen dizkiogu. Helburua testuzko historia ikusizko grafoaren osagarri gisa, soilik irudizko modalitate hutsaren gainetik dagoen sinergia bat sortzen duen zehaztea da. Edo kontrakoa, ea kaltegarria den erredundantzia bat sartzen duen.

Modalitate hibridoaren implementazioa Ebaluazioa aurrera eramateko, testuingurua nola eraiki eta inferentzia-motarrera (vLLM) bidali egokitu behar izan dugu. Irudi hutseko esperimentuan, ereduari pasatako karga, bloke heterogeneoen zerrenda batek osatzen du, non, zerrenda horrek, irudiaren tentsorea eta testu bloke minimo bat konbinatzen dituen. Bloke minimo honetan, instrukzio orokorrak eta azken galdera baino ez diogu pasatzen ereduari, beraz historiaren topologia guztia iruditik erauzi behar du ereduak. Modalitate anitzekoan, aldiz, irudiaren tentsorea pasatzen zaio, baina testuzko blokea historia deskriptibo osoa pasatuz aberasten da. Horrela, ereduaren arreta gurutzatuaren mekanismoak testuaren sekuentzia logikoa eta grafoaren irudikapen espaziala aldi berean prozesatzera behartzen dugu.

Modalitateen analisi konparatiboa Hiru kurbak (Testua, Irudia, Testua + Irudia) aurrez-aurre jartzean lortutako emaitzek eredu-familia guztietan ustekabeen oso uniformeak den

patroi bat erakusten dute (ikusi 4.6 irudia). Modalitateak konbinatzeak ez du inokako abantailarik sortzen irudia soilik erabiltzearen aldean.

Qwen3.5-9B Modalitate anitzeko kurbari erreparatuz gero, nabari da distantzia laburretan haren errendimendua oso altua dela, testu hutsaren aldaerara asko hurbilduz, izan ere, eredu horretan testu hutsaren aldaera bereziki indartsua da hasierako k balioetarako. Hala ere, konplexutasuna handitu ahala, kurba hibridoa, irudi hutsaren kurbaren azpitik kokatzen da, koherentea den moduan. Adibidez, $k = 50$ denean, irudi hutsaren modalitateak %47,5 lortzen du eta testuarekin konbinatuta %46ra jaisten da; $k = 100$ denean, arrakala handitu egiten da (%51,5 vs %42,5). Testu-modalitate hutsaren hondamendia nabarmen gaintitzen duen arren, testua txertatzeak ikusizko modalitatearen errendimendua zigortzen du.

InternVL3.5-8B Eredu honek modu are larriagoan erakusten du inpaktu negatiboa. Oinarrizko irudiaren modalitateak distantzia ertainetarako %50 – 60 tartean errendimendu nahiko egonkorra mantentzen duen bitartean, modalitate anitzeko kurbak beherakada drastikoa jasaten du lehen jauziaren ondoren, $k = 5$ etik aurrera %45 inguruan orbitatuz. Muturreko konplexutasunean, ($k = 100$), testuzko historia emateak eredia %31,5era jaitea eragiten du, ia 10 puntu galduz ikusizko grafoa soilik erabiltzen duen konfigurazioarekiko (%40,5).


Gemma-4-E4B-it Patroi hau *Gemma* arkitekturan ere errepikatzen da. Testuzko historia txertatzeak degradazio masibo goiztiar bat eragiten du. Irudi hutsak %75eko errendimendu sendoa mantentzen du $k = 5$ denean, eta modalitate anitzeko konfigurazioa %56ra amiltzen da. Espektoaren muturrean ($k = 100$), aldea gainerako ereduaren antzera egonkortzen da, zeren oinarrizko irudiak %42 gordetzen du eta hibridoak, ia 11 puntu gutxiago (%31).

Ondorioa: Testuzko erredundantziaren kaltea Esperimentu honetan bildutako datuek ezeztatu egiten dute erredundantzia deskriptiboa eskaintzeak ataza espaziala ebaztea errazten duela egiaztatzen duen hipotesia. Praktikan, argi ikusten da, testuzko historiak zarata gisa besterik ez duela jokatzeko, beharrezkoa ez den (eta gainera, kaltegarria den) lan karga sartuz. Ereduak historia osoa eskuragarri duenean, haren arreta-mekanismoak testuingurua sekuentzialki trazatu nahi du. Testua soilik erabili dugun esperimentuan ikusi dugun kolapso berdina jasaten du ereduak. Testuzko testuinguruaren leihorearen saturazio horrek talka egiten du ikusizko norabide-arrazoibidaren erauzketa holistikoarekin, eta metrikak behera arrastatzen ditu. Hori dela eta, irrimo ondorioztatzen da nodo asko dituzten grafoen gaineko inferentzia topologikorako atazetan, konfiguraziorik optimo eta egonkorrena sekuentzia linguistikoa erabat baztertzea eta irudizko bertsioari garrantzia ematea dela.


4.2.5 Arrazoiketa ereduaren ekarpena ebaluatzen

Aurreko esperimenduetan, inferentzia zuzeneko erantzunak behartzerak konfiguratu ditugu ereduak, tarteko arrazoibide-saiakerarik egin gabe. Hala ere, eredu moderno batzuk barne-hausnarketa blokeak, (*Chain-of-Thought*), sortzeko entrenatuta daude, azken erantzun bat igorri aurretik. Azken esperimentu honek arrazoibide logiko inplizitu hori aktibatzeak ereduaren errendimenduari nola eragiten dion ebaluatzen du. Modu honi *Thinking* modua deritzogu.


4. DISEINU ESPERIMENTALA ETA EMAITZAK



(a) Qwen



(b) InternVL



(c) Gemma

4.6 Irudia: Hiru ereduen errendimendu-kurbak: Modalitate Anitzeko Ikuspegia (T3).

Nabarmentzekoa da ebaluazio mota hau *Qwen3.5-9B* eta *Gemma-4-E4B-it* ereduekin bakarrik egin dela. Erabaki hori ez da ausazkoa, bi eredu hauek `< think > ... < /think >` moduko etiketen artean beren pentsamendu-katea modu natibo eta esplizituan konfinatzen dute. Beren prozesadorea `enable_thinking` parametroaren bidez kontrola daitekeenez, aukera ematen digute eredu berarekin arrazonomenduko eta hau gabeko bertsioak zuzenean eta baldintza berdinetan konparatzeko. *InternVL*-ren kasuan, aukera hau ematen ez digunez, ez dugu gehiago sakondu.

Testuzko arrazonomenduaren analisisa Testua + *Thinking* modalitatearen kurbak aztertu eta oinarritzko (testua soilik) aldaerarekin alderatzean, bi ereduek erabat kontrakoak diren joerak erakusten dituzte.

Qwen ereduen kasuan, inpaktua drastikoki kontraproduzentea da (ikusi 4.7a irudia). Ereduari labirinto topologikoa desegiten lagundu beharrean, testuaren gaineko pentsamendu-kate linguistikoa sortzera behartzeak haren zehaztasuna suntsitzen du. Oinarritzko moduan ereduak %72ari eustea lortzen bazuen $k = 5$ denean, *Thinking* modua aktibatzean metrika %37,5era amiltzen da. Degradazio hori esponentzialki larritzen da konplexutasuna handitu ahala: $k \geq 50$, *Thinking* modalitateko zehaztasuna %0ra jaisten da literalki. Fenomeno hori haluzinazio geometrikoaren begizta baten bidez azaltzen da, zeren ereduak gaizki inferitutako pauso bakoitzak ondorengo testuingurua kutsatzen du, akats-marjina metagarria sortuz.





Gemma ereduak, ordea, sendotasun handia erakusten du testuzko arrazoiketan (ikusi 4.7b irudia). Arkitektura honek bere barne-hausnarketa ondo egituratzeko gai dela erakusten du. *Thinking* modua aktibatzean, *Gemma*-k hobekuntza nabarmenak lortzen ditu

ibilbide gehienetan. $k = 2$ denean %59,5 etik %71ra igotzen da, eta $k = 5$ denean, %33tik %50era. Soilik muturreko konplexutasunetan ($k = 100$) hasten da zarata metatzen eta errendimendua arrazonomendu gabeko bertsioaren azpitik erortzen da (%15tik %9ra).

Ikusizko arrazonomenduaren analisisia *Thinking* moduaren portaera irudikapen grafiko batean oinarritzen denean (Irudia soilik + *Thinking*), dinamika aldatzen dira.

Qwen ereduaren kurbak bi fase bereizten ditu (ikus 4.7c irudia). Distantzia laburretan $k \leq 2$, arrazoibide esplizituak "gain-analisi" moduko bat sartzen du, eta horrek zehaztasuna jaistea eragiten du (%90,5etik %76ra $k = 2$ denean). Hasierako ikusizko inpaktua erlazioa deduzitzeko nahikoa denean (grafo txikietan, k -ren balio baxuetan) tarteko testua sortzeak zarata gehitzen du. Hala ere, konplexutasuna muturreko bihurtu ahala ($k = 100$), arrazonomendu blokeak ereduari sare masiboetan galtzea saihesten dio, oinarritzko irudiaren errendimendua gaindituz (%47,5etik %53ra igoz $k = 50$ denean).

Gemma-ren kasuan (ikus 4.7d irudia), gain-analisiaren zigor hori askoz ere zabalagoa da. Salbuespen bat kenduta ($k = 1$ denean %81etik %90,5era igotzen da), arrazonomendu blokea aktibatzeak irudiaren prozesamendua modu orokorrean okertzen du kurbaren gaineko balio guztietan. Adibidez $k = 5$ denean asmatze-tasa %75etik %67ra jaisten da. *Gemma*-k ikusmen-ezaugarriak zuzenean ondo prozesatzen ditu, eta horiek hitz bihurtzera behartzeak fluxua oztopatzen duela dirudi.

(a) Qwen: Testu hutsa vs. Testua + *Thinking*(b) Gemma: Testu hutsa vs. Testua + *Thinking*(c) Qwen: Irudi hutsa vs. Irudia + *Thinking*(d) Gemma: Irudi hutsa vs. Irudia + *Thinking*

4.7 Irudia: Qwen eta Gemma ereduaren errendimendu-kurbak: *Thinking* moduaren eragina testuan eta irudietan.


Ondorioa: Arrazoiketa-moduen menpekotasuna ereduarekiko. Esperimentu honen emaitzek agerian uzten dute Chain of Thought mekanismoa ez dela soluzio unibertsala

edo magikoa arrazoibide topologikorako. Eredu baten arrakasta ez dator bere arkitekturatik —gaur egungo MLLM-en artean ez baitago egitura-alde nabarmenik—, baizik eta, batez ere, bere entrenamendu-prozesuaren eta ikaskuntzarako erabilitako datuen araberakoa da. *Gemma* bezalako eredu batek testu-datuen gaineko inferentzia logikoa nabarmen hobetu dezake Thinking moduari esker, baina ikusizko datu argiak deskribatzera behartzen denean, errendimendua gal dezake. *Qwen*-ek, aldiz, testu hutseko haluzinazio-begiztak jasaten ditu, baina irudi konplexuen aurrean ongi transkribitzen du testura. Ondorioz, konfiguraziorik optimoena erabiltzen den modalitatearen (testua edo irudia) eta ereduaren beraren izaeraren (entrenamenduaren) arteko oreka bat da.

4.3 Eztabaida

Lan honetan burututako esperimentuek hainbat ondorio esanguratsu utzi dituzte ereduaren arrazoibide espazialari eta informazio topologikoaren prozesamenduari dagokionez:

- **Irudien egonkortasuna arrazoibide espazialean:** Emaitzek argi erakusten dute ikusizko modalitatea erabiltzea askoz ere lagungarriagoa dela arrazoibide espaziale-rako, testu hutseko sekuentziekin alderatuz. Grafoaren konplexutasuna eta nodo kopurua (k) handitu ahala, sekuentzia linguistikoek errendimenduaren kolapsoa jasaten dute, konplexutasunaren hazkundera modu egonkorrean xurgatuz eta zehaztasunari askoz hobeto eutsiz.
- **Ikusizko identifikazioaren botila-lepoa:** Ikusizko informazioa prozesatzeko orduan, ereduak zailtasun nabarmenak dituzte galderan zehazten zaizkien bi nodoak bilatzeko eta identifikatzeko. Esperimentuetan ikusi den bezala, identifikazio hori artifizialki erraztean (adibidez, ibilbideak geziekin markatuz), emaitzak modu esanguratsuan hobetzen dira. Horrek frogatzen du ikusmen-arretan dagoela mugarik handienetako bat, espazioari buruzko arrazoiketa-gaitasun inplizituan baino gehiago.
- **Modalitate-anitzeko sarreraren erredundantziaren kaltea:** Ikusizko errepresentazioei testuzko historia gehitzeak ez du sinergiarik edo onurarik ekartzen. Are gehiago, bi modalitateak batera erabiltzeak emaitzak okertzen ditu, bereziki k balio handientzat. Testuinguru deskriptiboak zarata gisa jokatzen du, ereduaren arretamekanismoak aseturik eta irudi hutsak eskaintzen duen erauzketa norabide-espazial holistikoa oztopatuz.
- **Arrazoiketa-ereduen ekarpen ezberdinak eredu motarekiko:** Ereduak barnehausnarketa (Chain of Thought edo Thinking modua) egitera behartzeak ez du testuaren nahiz irudiaren degradazioa modu unibertsalean konpontzen; aitzitik, lortutako emaitzak ereduaren entrenamendu-prozesuaren eta datu-ikaskuntzaren araberakoak dira erabat. *Qwen* ereduaren kasuan, testuaren gaineko arrazoibideak haluzinazioak areagotu eta degradazioa dakarren arren, ikusizko errepresentazioetan lagungarria da nodo askoko grafoetan ez galtzeko. *Gemma*-k, ordea, portaera alderantzikatu erakusten du: testuzko datuekin arrazoibide logikoa nabarmen hobetzen du, baina ikusizko datu argiak deskribatzera behartzean, errendimendua modu orokorrean okertzen du. Ondorioz, arrazoiketa esplizitua ez da soluzio absolutua, sarrera-modalitatearen eta ereduaren izaeraren arabera egokitu beharreko aldaera baizik.



Ondorioak eta Etorkizuneko Lana

Lan honen helburu nagusia Modalitate Anitzeko Hizkuntza-Eredu Erraldoietan (MLLMtan) arrazoibide espazialerako eta informazio topologikoa prozesatzeko duten gaitasuna ebaluatzea izan da. Horretarako, testu bidezko eta irudi bidezko modalitateak, haien arteko konbinazioak eta barne-arrazoiketarako mekanismoak (Chain of Thought) aztertu dira sare topologikoen gainean. Atal honetan ikerketaren ondorio nagusiak laburbiltzen dira eta etorkizuneko ikerketa-ildoak proposatzen dira.

5.1 Ondorio Nagusiak

Egindako esperimentuek eta lortutako emaitzek eredu hauen funtzionamenduari buruzko hainbat aurkikuntza esanguratsu utzi dituzte:

- **Ikusizko irudikapenaren nagusitasuna eta egonkortasuna:** Arrazoibide espazialari dagokionez, irudien erabilera testu hutsezko sekuentziak baino askoz ere egonkorragoa eta eraginkorragoa dela frogatu da. Grafoaren konplexutasuna eta nodo kopurua (k) handitu ahala, hizkuntza naturaleko sekuentziek muga kognitiboak pairatzen dituzte eta errendimendua kolapsatu egiten da. Ikusizko irudikapenak, aldiz, egitura espazial globala urrats bakarrean prozesatzeko aukera ematen du, asmatze-tasari askoz hobeto eutsiz.
- **Ikusizko arretaren botila-lepoa (Visual Bottleneck):** Ereduen hutsegite asko ez datoz espazioari buruzko arrazoibide logikoaren gabeziatik, nodo zehatzak ingurune trinko batean aurkitzeko eta identifikatzeko ezintasunetik baizik. Entitateen lokalizazioa artifizialki erraztu denean (geziak edo koloreak erabiliz), ereduaren errendimendua nabarmen hobetu da. Honek erakusten du ikusizko identifikazioa ataza espazialen muga garrantzitsuenetako bat dela.
- **Modalitate anitzeko testuinguruak dakarren zarataren kaltea:** Irudizko errepresentazioei testuzko historia sekuentziala gehitzeak ez du espero zen sinergiarik sortu. Aitzitik, erredundantzia deskriptiboa txertatzeak errendimendua okertu du saretze handietan. Testuak zarata gisa jokatzek du, ereduaren arreta-mekanismoak asetzen ditu eta irudiak eskaintzen duen erauzketa holistikoa oztopatzen du.

- **Arrazoiketa-moduen (Thinking) eragin aldakorra eta ereduarekiko menpekotasuna:** Ereduak hausnarketa esplizitua egitera behartzeak ez dakar hobekuntza unibertsalik. Emaizak arkitekturaren eta entrenamenduaren menpe daude erabat. *Qwen*-en kasuan, testu bidezko arrazoibideak haluzinazioak areagotu ditu, baina irudi konplexuetan lagungarria izan da; *Gemma*-k, aldiz, aurkako joera erakutsi du, testuarekin hobetuz baina irudi hutsekin degradazioa jasanez.

5.2 Etorkizunerako Lana

Ikerketa honetan lortutako emaitzek eta identifikatutako mugek bide berriak irekitzen dituzte modalitate anitzeko hizkuntza-ereduen arrazoibide espaziala hobetzeko. Jarraian, etorkizunean jorratu daitezkeen ikerketa-ildoak aipatzen dira:

- **Ikusizko arreta-mekanismoak hobetzea (Visual Grounding):** Lan honetan egiaztatu denez, ikusizko identifikazioa botila-lepo garrantzitsua da. Etorkizuneko lan batek ikusizko arreta bideratzeko teknika berriak ikertu ditzake, ereduak modu autonomoan eta zehatzagoan gai izan daitezen irudi trinkoetan entitate zehatzak lokalizatzeko, laguntza artifizialaren (geziak edo koloreak) beharrik gabe.
- **Eredu jabedun eta handiangoekin konparaketa:** Ikerketa hau *Qwen*, *InternVL* eta *Gemma* bezalako eredu irekiekin burutu da. Interesgarria litzateke ebaluazio-esparru bera aplikatzea merkatuan dauden puntako eredu itxiekin (adibidez, *GPT-4o*, *Claude 3.5 Sonnet* edo *Gemini 1.5 Pro*). Horrek aztertzea ahalbidetuko luke ea identifikatutako mugak (hala nola testu-erredundantziaren kaltea) modalitate anitzeko ereduen arazo arkitektoniko unibertsalak diren, ala eredu handiagoetan leundu egiten diren.
- **Modalitate anitzeko sinergia lortzeko *Fine-Tuning* edo *Lerrokatzeta (Alignment)*:** Testua eta irudia batera erabiltzean errendimendua jaitsi egin dela ikusirik, etorkizuneko lan batek ereduen doikuntza finera bideratu lezake indarrak. Helburua litzateke ereduak entrenatzea testua eta irudia modu osagarrian prozesatu ditzaten, bata bestearen zarata bihurtu beharrean.
- **Hiru dimentsioetako espazio eta ingurune dinamikoen ebaluazioa:** Ikerketa hau bi dimentsiotako grafo estatikoetan oinarritu da. Hurrengo urrats logiko bat ereduen arrazoibide gaitasuna hiru dimentsiotako inguruneetan edo bideo bidezko ingurune dinamikoetan (non entitateen topologia eta posizioak denboran zehar aldatzen diren) ebaluatzea litzateke.
- ***Prompt Engineering* teknika aurreratuak espazio-atazetarako:** *Chain of Thought* mekanismo estandarrak emaitza aldakorrek eman dituzenez, etorkizuneko lan batek soilik arrazoibide espazial eta topologikorako diseinatutako instrukzio egituratu berriak ikertu ditzake, ereduak haluzinazio espazialak saihestera bideratzeko.

Erabilitako Promptak

A.1 0-shot Prompt

```
{
  "id": "{line['ID']}",
  "messages": [
    {
      "role": "user",
      "content": "Given a story about spatial relations among objects,
answer the relation between two queried objects. Possible relations are:
above, below, left, right, upper-left, upper-right, lower-left, and
lower-right. If a sentence in the story is describing clock-wise
information, then 12 denotes above, 1 and 2 denote upper-right,
3 denotes right, 4 and 5 denote lower-right, 6 denotes below,
7 and 8 denote lower-left, 9 denotes left, 10 and 11 denote
upper-left. If the sentence is describing cardinal directions,
then north denotes above, east denotes right, south denotes below,
and west denotes left.
```

Answer the question and provide the final answer in the form:
'### Answer:'

```
Story:
{line['data'].replace('\n', '\n')}

{line['question'].replace('\n', '\n')}
}
]
}
```

A.2 5-shot Prompt

```
{
  "id": "{line['ID']}",
  "messages": [

    {
      "role": "user",
      "content": "Given a story about spatial relations among objects,

answer the relation between two queried objects. Possible relations are:
above, below, left, right, upper-left, upper-right, lower-left,
and lower-right. If a sentence in the story is describing clock-wise
information, then 12 denotes above, 1 and 2 denote upper-right,
3 denotes right, 4 and 5 denote lower-right, 6 denotes below,
7 and 8 denote lower-left, 9 denotes left, 10 and 11 denote
upper-left. If the sentence is describing cardinal directions,
then north denotes above, east denotes right, south denotes below,
and west denotes left.
```

```
Answer the question and provide the final answer in the form:
'### Answer:'
```

```
Story:
1 XU is to the right and below XJX at an angle of about 45 degrees.
```

```
What is the relation of the agent XU to the agent XJX?"
```

```
},
{
  "role": "assistant",
  "content": "### Answer: lower-right"
},
```

```
{
  "role": "user",
  "content": "Story:
```

```
1 XEX is to the bottom right of XEM.
2 XFR is positioned up and to the right of XEM.
3 XEX is to the left of XJM with a small gap between them.
```

```
What is the relation of the agent XJM to the agent XFR?"
```

```
},
{
  "role": "assistant",
  "content": "### Answer: lower-right"
},
```

```

{
  "role": "user",
  "content": "Story:

1 XAV is positioned right to XH.
2 XH is on the right and XDC is on the left.
3 XAE and XJT are vertical and XAE is below XJT.
4 XDC presents over XJT.
5 XEG is sitting at the 6:00 position to XAE.

What is the relation of the agent XAV to the agent XEG?"
},
{
  "role": "assistant",
  "content": "### Answer: upper-right"
},

{
  "role": "user",
  "content": "Story:

1 The object labeled XBK is positioned to the right of the object
labeled XGX.
2 XDT is over XGX.
3 XIC is below XDT and to the left of XDT.
4 XIC and XBD are in a vertical line with XIC on top.
5 XBD is south east of XFT.
6 If XFT is the center of a clock face, XDV is located between 7 and 8.
7 XDV is positioned below XFY.

What is the relation of the agent XFY to the agent XBK?"
},
{
  "role": "assistant",
  "content": "### Answer: left"
},

{
  "role": "user",
  "content": "Story:

1 XJV and XEJ are horizontal and XJV is to the left of XEJ.
2 XJV is directly north east of XEX.
3 XEX is to the right of XDU horizontally.
4 XDU and XCF are vertical and XDU is above XCF.
5 XQ is on the left side and above XCF.

```

6 XQ and XGQ are side by side with XQ to the right and XGQ to the left.
7 XGQ is over there and XIY is directly above it.
8 The object XIY and XDV are there. The object XIY is below and slightly to the right of the object XDV.
9 XCN is at a 45 degree angle to XDV, in the lower lefthand corner.

What is the relation of the agent XCN to the agent XEJ?"

```
},  
{  
  "role": "assistant",  
  "content": "### Answer: left"  
},  
  
{  
  "role": "user",  
  "content": "Story:  
  
{line['data'].replace('\n','\n')}  
  
{line['question'].replace('\n','\n')}"  
}  
  
]  
}
```


Proiektuaren helburuen dokumentua

Eranskin honetan, proiektuaren plangintza aurkezten da, helburu orokorrak, zereginen banaketa lan-paketetan, denboren estimazioa eta Gantt-en diagrama barne. Horrez gain, jarraitutako lan-metodologia eta identifikatutako arriskuak zehazten dira, horiek ekiditeko estrategiekin batera.


B.1 Deskribapena eta helburuak

Arrazonamendu espaziala Modalitate Anitzeko Hizkuntza Eredu Erraldioen (MLLM) ebaluazioaren arlo funtsezkoetako bat da, eredu hauek objektuen arteko espazio-harremanak (*above, below, left, right...*) nola ulertzen dituzten aztertzen duena. Eredu hauek harremanen konplexutasuna handitzen denean erakusten duten portaerak galdera irekia uzten du: benetan arrazonamendu espazial konplexua gauzatzen duten ala azaleko eredu estatistikoak bakarrik garatzen dituzten.

Proiektu honen helburu nagusia MLLMen jauzi anitzeko (*multi-hop*) espazio-arrazonamendu gaitasunen sakontasuna eta mugak sistematikoki ebaluatzea da. Horretarako, k aldagaiak (*nhop*) adierazten duen salto-kopurua erabiliz zailtasuna eskalarazten da, testu- eta ikusmen-modalitateak alderatuz eta datuen irudikapenaren eta *thinking mode*-aren eraginak aztertuz, ereduen ahultasunak eta indarguneak identifikatzeko.

B.2 Plangintza

Proiektu honen arrakasta bermatzeko eta ezarritako helburuak bete ahal izateko, ezinbestekoa da plangintza on bat definitzea. Kapitulu honetan diseinatutako plangintza zehazten da, bertan, lanaren deskonposaketa, denboraren kudeaketa, proiektuaren mugarriak, erabili beharreko baliabideak eta arriskuen analisisa azaltzen dira.



B.1 Irudia: Proiektuaren plangintza orokorra.

B.2.1 Lanaren deskonposaketa egitura

Lanaren Deskonposaketa Ereduaren (LDE) diagrama funtsezko tresna bat da proiektuaren kudeaketa on bat burutzeko, bertan garatu beharreko atazak lan-paketeetan banatzen baitira. Proiektu honi dagokion LDE diagrama, ?? irudian aurkezten da.

Lan-paketeak bost ataletan banatzen dira: kudeaketa, informazio bilketa, prestakuntza tekniko, proiektuaren garapena eta dokumentazioa.

Kudeaketa Atal honetan, proiektuaren garapena planifikatu eta gainbegiratzen da. Honetarako, proiektua bideratzeko bi lan-pakete definitu dira:

- **Plangintza:** Proiektuaren plangintza egitean datza. Besteak beste, atazak eta hauen denboraldiak definitzea, lan-metodologia zehaztea eta arriskuak kudeatzea.
- **Jarraipena eta kontrola:** Proiektuak modu eraginkorrean aurrera egiten duela eta ezarritako epeak betetzen direla bermatzea du helburu.

Informazio bilketa Atal honetan, arloko informazioa bilatzea, baliabide garrantzitsuak identifikatzea eta hurrengo faseetan erabiliko diren tresnak eta teknologiak hautatzea bezalako atazak sartzen dira. Proiektuaren garapenerako ezagutza-oinarri sendoa ezartzea du helburu.

Prestakuntza tekniko Atal honetan, proiektuaren ingurune teknikora egokitzeko jarduerak sartzen dira. Esperimentuekin hasi aurretik egin beharreko oinarritzko lana da. Bi lan-pakete definitu dira:

- **Eredu(a/ekin) ohitzea:** Qwen3.5-9B, InternVL3.5-8B eta Gemma-4-E4B-it ereduak aztertzea eta hau erabiltzen ikastea jasotzen ditu.
- **Datu-multzoaren azterketa:** Lan-pakete hau DecompsR datu-multzoa aztertzean, eta behar bezala prestatzean datza, ondorengo esperimentuetan erabiltzeko.

Proiektuaren garapena Adar honetan esperimentaziorako bete beharreko eginkizun guztiak sartzen dira, besteak beste, esperimentuen diseinua, inplementazioa eta emaitzen analisia.

- **Esperimentuen diseinua:** Behin oinarriak definituta daudela, egin nahi diren esperimentuak diseinatzean datza lan-pakete hau.
- **Esperimentuen inplementazioa:** Diseinatutako esperimentuen inplementaziorako loturiko ataza guztiak jasotzen ditu.
- **Emaitzen analisia:** Esperimentuen emaitzak jasotzea eta hauen analisia egitean datza, ondorioak ateratzeko.

Dokumentazioa Atal honetan, proiektuaren memoria sortzeko eta defentsa prestatzeko lana bideratzen da.

- **Memoria:** Memoria idaztearekin loturiko ataza guztiak jasotzen ditu. Honen emaitza proiektuaren garapenaren xehetasunak biltzen dituen dokumentua da.
- **Aurkezpena:** Proiektuaren defentsarako prestakuntzarekin loturiko eginkizun guztiak biltzen dira lan-pakete honetan. Honen helburua memoriako ideia nagusiak modu argi eta antolatuan jasotzea da.

B.2.1.1 Denboraren kudeaketa

Denboraren kudeaketa funtsezkoa da edozein proiektu planifikatu eta gauzatzeko, ezarritako mugarriak betetzea eta proposatutako helburuak lortzea ahalbidetzen baitu. Kasu honetan, proiektua 300 ordutan osatu behar da. Lana ezarritako denboran burutzeko, lan-paketeen etapak zehazten dituen Gantt diagrama eta denboren taula osatu dira.

B.2 irudiko Gantt diagramak proiektuko lan-pakete bakoitzaren denboraldia eta gainontzeko paketeekiko dependentziak jasotzen ditu. Bertan ikus daiteke, informazio bilketako, proiektuaren garapeneko eta dokumentazioko lan-paketeak modu nahiko sekuentzialean burutzen direla. Bestalde, lanaren jarraipena eta kontrola, proiektu osoan zehar burutzen da.

Proiektuaren denbora taula B.1 taulan ageri da. Bertan, lanaren deskonposaketan zehaztutako lan-pakete bakoitzari dedikatuko zaion orduen estimazioa adierazten da. Horrekin batera, guztira atal bakoitzari dedikatu beharreko ordu kopurua ageri da. Taulan ikusten da garrantzi gehiena proiektuaren garapenari eta dokumentazioari emango zaiela, bakoitzari 85 ordu inguru beharko zaizkiola estimatu baita. Hauei gainontzeko atalen orduak batuta, guztira Gradu Amaierako Lanak bete beharko lituzkeen 300 orduak lortzen dira.

B.2.2 Emangarri eta mugarriak

Gradu Amaierako Lanean bi emangarri nagusi daude, memoria eta defentsa, eta bakoitzak entregatze- edo aurkezpen-data bat du. Horrez gain, hauek entregatu ahal izateko, lehenik defentsa-eskaera egin behar da, beraz, guztira hiru mugarri izango dira kontuan hartu beharrekoak.

B. PROIEKTUAREN HELBURUEN DOKUMENTUA

Lan paketea	Otsaila	Martxoa	Apirila	Maiatza	Ekaina
Kudeaketa					
Plangintza					
Jarraipena eta kontrola					
Informazio bilketa					
Prestakuntza teknikoa					
Datu-multzoaren azterketa					
Eredukin ohitzea					
Proiektuaren garapena					
Esperimentuen diseinua					
Esperimentuen inplementazioa					
Emaizten analisia					
Dokumentazioa					
Memoria					
Aurkezpena					

B.2 Irudia: Proiektuaren Gantt diagrama.

Lan-paketea	Estimazioa (orduak)
Plangintza	20
Jarraipena eta kontrola	20
Proiektuaren kudeaketa	40
Informazio bilketa	40
Datu-multzoaren azterketa	15
Eredukin ohitzea	35
Prestakuntza teknikoa	50
Esperimentuen diseinua	15
Esperimentuen inplementazioa	55
Emaizten analisia	15
Proiektuaren garapena	85
Memoria	70
Aurkezpena	15
Dokumentazioa	85
Guztira	300

B.1 Taula: Lan-pakete bakoitzerako denboraren estimazioa.

Emangarria	Epemuga
Defentsaren eskaera	Ekainaren 15a
Memoriaren entrega	Ekainaren 21a
Proiektuaren defentsa	Ekainaren 29tik uztailaren 15era

B.2 Taula: Emangarri bakoitzaren epemuga.

B.3 Lan-metodologia

Proiektu hau aurrera eramateko, lanaren beharretara egokitutako metodologia erabili da. Atal honetan, alde batetik, inplementaziorako eta esperimenezko erabilitako metodologia eta baliabideak zehazten dira. Beste aldetik, tutoreekiko komunikazio-sistema eta bileren antolaketa deskribatzen dira.

B.3.1 Garapena eta baliabideak

Esperimentaziorako jarraitutako metodologia bi fase nagusitan oinarritzen da: lehenik eta behin, hasierako proba sinpleak egitea, funtzionamendua ziurtatzeko eta beharrezko parametroak doitzeko. Ondoren, esperimentu osoak egitea jakinik seguruenik ez direla arazo batengatik etengo.

Proiektu honen ardatza MLLM zehatz batzuen jauzi anitzeko arrazonomendu espazialaren inguruko problemak bere gain hartzen dituen DecompSR datu-multzoarenganako zehaztasuna neurtzea denez funtsezkoa da lan-ingurune egoki bat hautatzea. Esaterako, aukeratutako inguruneak beharrezko gaitasun konputazionala eta zereginak burutzeko eraginkortasuna ziurtatu behar ditu.

Testuinguru honetan, esperimentuen hasierako probak eta proba sinpleak Google Colaboratory ingurunean egingo dira, hau erabiltzeko erraztasuna eta Python-eko liburutegiekin duen integrazioa aprobetxatuz. Hala ere, plataforma honek konputazio-gaitasun mugak ditu, beraz, esperimentuen exekuzio osoak IXA taldeko zerbitzarietan egingo dira. Zerbitzari hauek kalkulu-potentzia handiagoa eta datu-bolumen handiak prozesatzeko gaitasuna dute, ingurune egokiagoa eskainiz.

B.3.2 Komunikazio-sistema

Bileren antolaketari dagokionez, ez da egutegi finkorik ezarri. Horren ordez, ikuspegi malgua hautatu da, behar denean bilerak eskatzeko aukera emanez. Hala ere, erregulartasun bat mantentzen saiatuko da, proiektuaren aurrerapena bermatzeko.

Bilera hauen helburuak, zalantzak argitzea, emaitzak eztabaidatzea eta lanaren hurrengo urratsak zehaztea izango dira.

Bestalde, bat-batean zalantzaren bat izanez gero, posta elektronikoa erabiliko da ahalik eta azkarren argitzeko.

B.4 Arriskuak eta prebentzioa

Atal honetan, proiektuaren garapenean sor litezkeen arriskuak identifikatzen dira, eta haien eragina eta probabilitatea ebaluatzen dira. Gainera, prebentzio-estrategiak eta -neurriak

proposatzen dira, arriskuen probabilitatea minimizatzeko eta ezarritako helburuak betetzen direla bermatzeko.

1. **Plangintzarekiko desbiderapen nabarmenak.** Plangintzarekiko desbiderapen handia izateak, hau berriro planteatzera eraman dezake. Horregatik, funtsezkoa da marjina egokiak ezartzea atazen denboraldiak definitzean.
2. **Helburuetara ez iristea.** Definitutako irismena eta helburuak gehiegizkoak izatea gerta liteke. Egoera honen aurrean, irismen txikiagoko helburuak definitzea edo proiektua hurrengo deialdian aurkeztea aztertu beharko litzateke.
3. **Kontzeptu teorikoak ulertzeko zailtasuna.** Arlo honek kontzeptu teoriko ugari menderatzea eskatzen du, eta horiek ulertzea erronka bat izan daiteke. Horregatik, funtsezkoa da kontzeptu hauek behar bezala barneratzeko behar den denbora hartzea.
4. **Datu edo fitxategiak galtzea.** Proiektuan zehar sortutako datu eta emaitzak galtzeak arazo larriak sor ditzake. Hau ekiditeko, GitHub erabiliko da, fitxategiak gordetzeko ingurune segurua eta bertsio-kontrolerako tresna gisa.



AA sortzailearen erabilera deklarazioa

Erabilitako tresna/k:

Google Gemini Pro, Claude, ChatGPT, Latxa eta Overleaf AI.

Egindako erabilera (dagokiona markatu):

- ☒ Testu-sorkuntza
- ☒ Birformulazioa
- ☒ Itzulpena / zuzenketa
- ☒ Egituraren iradokizuna
- ☐ Laguntza metodologikoa
- ☒ Kodetzeko / programatzeko laguntza
- ☐ Beste batzuk

Egindako erabileraren deskribapena:

Lan honetan, adimen artifizial sortzaileko hainbat tresna (Google Gemini Pro, Claude, ChatGPT, Latxa eta Overleaf AI) erabili dira idazketa-prozesuan eta maketazioan laguntzaile gisa. Alde batetik, testuei tonu akademiko egokia emateko, Laburpena eta Sarrera atalak egituratzeko, eta Garapen Jasangarriko Helburuei (GJH) buruzko atala idazteko oinarria sortzen lagundu dute. Horrez gain, Latxa ereduaren laguntzaz edukiak euskarara itzuli dira. Bestetik, programazioari eta maketazioari dagokionez, aurreko ereduez gain Overleaf-en integratutako IA erabili da LaTeX bidezko dokumentua osatzeko, kodearen arazo teknikoak identifikatu eta konpontzeko (irudi anitzeko egiturak sortzean, esaterako) eta kapituluaren erreferentzia gurutzatuak automatizatzeko.

Autoretza konpromisoa:

Sortutako eduki guztia pertsonalki berrikusi, berregin eta balioztatu dudala bermatzen dut.

Bibliografia

- [1] Qwen Team. Qwen3.5: Towards native multimodal agents, February 2026.
- [2] Weiyun Wang, Zhangwei Gao, Lixin Gu, Hengjun Pu, Long Cui, Xingguang Wei, Zhaoyang Liu, Linglin Jing, Shenglong Ye, Jie Shao, et al. Internvl3.5: Advancing open-source multimodal models in versatility, reasoning, and efficiency. *arXiv preprint arXiv:2508.18265*, 2025.
- [3] Clement Farabet and Olivier Lacombe. Gemma 4: Byte for byte, the most capable open models. <https://blog.google/innovation-and-ai/technology/developers-tools/gemma-4/>, apr 2026. The Keyword - Google Blog. Accedido: 11 de junio de 2026.
- [4] Sepp Hochreiter and Jürgen Schmidhuber. Long short-term memory. *Neural computation*, 9(8):1735–1780, 1997.
- [5] Yoshua Bengio, Patrice Simard, and Paolo Frasconi. Learning long-term dependencies with gradient descent is difficult. *IEEE transactions on neural networks*, 5(2):157–166, 1994.
- [6] Tom B. Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33:1877–1901, 2020.
- [7] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, AidanÑ Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *Advances in Neural Information Processing Systems*, volume 30, 2017.
- [8] Jianlin Su, Yu Lu, Shengfeng provisions Pan, Ahmed Murtadha, Wen Bo, and Yexiang Liu. Ro-former: Enhanced transformer with rotary position embedding. *Neurocomputing*, 568:127063, 2024.
- [9] Jared Kaplan, Sam McCandlish, Tom Henighan, Tom B Brown, Benjamin Chess, Rewon Child, Scott Gray, Alec Radford, Jeffrey Wu, and Dario Amodei. Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*, 2020.
- [10] Jason Wei, Yi Tay, Rishi Bommasani, Colin Raffel, Xiaohua Zhai, Sebastian Borgeaud, Dani Yogatama, Maarten Bosma, Denny Zhou, Donald Metz, et al. Emergent abilities of large language models. *arXiv preprint arXiv:2206.04615*, 2022.
- [11] Long Ouyang, Jeffrey Wu, Xu Jiang, Diogo Almeida, Carroll Wainwright, Pamela Mishkin, Chong Zhang, Sandhini Agarwal, Katarina Slama, Alex Ray, et al. Training language models to follow instructions with human feedback. In *Advances in Neural Information Processing Systems*, volume 35, pages 27730–27744, 2022.
- [12] Jason Wei, Xuezhi Wang, Dale Schuurmans, Maarten Bosma, Fei Xia, Ed Chi, Quoc V Le, Denny Zhou, et al. Chain-of-thought prompting elicits reasoning in large language models. In *Advances in Neural Information Processing Systems*, volume 35, pages 24824–24837, 2022.
- [13] Ziwei Ji, Nayeon Lee, Rita Frieske, Tiezheng Yu, Dan Su, Yan Xu, Etsuko Ishii, Yejin Bang, Andrea Madotto, and Pascale Fung. Survey of hallucination in natural language generation. *ACM Computing Surveys*, 55(12):1–38, 2023.
- [14] Sebastian Raschka. Understanding multimodal LLMs. Ahead of AI Newsletter, November 2024.

- [15] Wenliang Dai, Nayeon Lee, Boxin Wang, Zhuolin Yang, Zihan Liu, Jon Barker, Tuomas Rintamaki, Mohammad Shoeybi, Bryan Catanzaro, and Wei Ping. NVLM: Open frontier-class multimodal LLMs. *arXiv preprint arXiv:2409.11402*, 2024.
- [16] Shukang Yin, Chaoyou Fu, Sirui Zhao, Ke Li, Xing Sun, Tong Xu, and Enhong Chen. A survey on multimodal large language models. *arXiv preprint arXiv:2306.13549*, 2023.
- [17] Deyao Zhu, Jun Chen, Xiaoqian Shen, Xiang Li, and Mohamed Elhoseiny. Minigpt-4: Enhancing vision-language understanding with advanced large language models. *arXiv preprint arXiv:2304.10592*, 2023.
- [18] Anas Awadalla, Irena Gao, Josh Gardner, Jack Hessel, Yusuf Hanafy, Wanrong Zhu, Kalyani Marathe, Yonatan Bitton, Samir Gadre, Shiori Sagawa, et al. Openflamingo: An open-source framework for training large autoregressive vision-language models. *arXiv preprint arXiv:2308.01390*, 2023.
- [19] Alexey Dosovitskiy, Lucas Beyer, Alexander Kolesnikov, Dirk Weissenborn, Xiaohua Zhai, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer, Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, and Neil Houlsby. An image is worth 16x16 words: Transformers for image recognition at scale. In *International Conference on Learning Representations*, 2021.
- [20] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. In *Proceedings of the 38th International Conference on Machine Learning*, volume 139 of *Proceedings of Machine Learning Research*, pages 8748–8763, 2021.
- [21] Shuai Bai, Keqin Chen, Xuejing Liu, Jialin Wang, Wenbin Ge, Sibo Song, Kai Dang, Peng Wang, Shijie Wang, Jun Tang, Humen Zhong, Yanzhi Zhu, Mingkun Yang, Zhaohai Li, Jianqiang Wan, et al. Qwen2.5-VL technical report. *arXiv preprint arXiv:2502.13923*, 2025.
- [22] Haotian Liu, Chunyuan Li, Yuheng Li, Bo Li, Yuanhan Zhang, Chengyi Shen, and Yong Jae Lee. Llava-next: Improved reasoning, ocr, and world knowledge. *arXiv preprint arXiv:2401.13601*, 2024.
- [23] Haotian Liu, Chunyuan Li, Yuheng Li, and Yong Jae Lee. Improved baselines with visual instruction tuning. *arXiv preprint arXiv:2310.03744*, 2023.
- [24] Jean-Baptiste Alayrac, Jeff Donahue, Pauline Luc, Antoine Miech, Iain Barr, Yana Hasson, Karel Lenc, Arthur Mensch, Katherine Millican, Malcolm Reynolds, et al. Flamingo: a visual language model for few-shot learning. In *Advances in Neural Information Processing Systems*, volume 35, pages 23716–23736, 2022.
- [25] Haotian Liu, Chunyuan Li, Qingyang Wu, and Yong Jae Lee. Visual instruction tuning. In *Advances in Neural Information Processing Systems*, volume 36, 2023.
- [26] Yash Goyal, Tejas Khot, Douglas Summers, Dhruv Batra, and Devi Parikh. Making the v in vqa matter: Elevating the role of image understanding in visual question answering. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 6904–6913, 2017.
- [27] Yuliang Liu, Zhang Li, Biao Li, Lianwen Jin, et al. On the hidden mystery of ocr in large multimodal models. *arXiv preprint arXiv:2305.07895*, 2023.
- [28] Minesh Mathew, Dimosthenis Karatzas, and CV Jawahar. Docvqa: A dataset for vqa on document images. In *Proceedings of the IEEE/CVF winter conference on applications of computer vision*, pages 2200–2209, 2021.
- [29] Ahmed Masry, Do Xuan Long, Jia Qing Tan, Shafiq Joty, and Enamul Hoque. Chartqa: A benchmark for question answering about charts with visual and logical reasoning. In *Findings of the Association for Computational Linguistics: ACL 2022*, pages 2263–2279, 2022.

-
- [30] Aniruddha Kembhavi, Mike Salvato, Eric Kolve, Minjoon Seo, Hannaneh Hajishirzi, and Ali Farhadi. A diagram is worth a dozen images. In *European conference on computer vision*, pages 235–251. Springer, 2016.
 - [31] Xiang Yue, Yuansheng Ni, Kai Zhang, Tianyu Zheng, Liu Ruoqi, Dianbo Ge, Dong Dong, et al. Mmmu: A massive multi-discipline multimodal understanding and reasoning benchmark for expert agi. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9556–9567, 2024.
 - [32] Pan Lu, Hritik Bansal, Tony Xia, Jiarui Liu, Chunyuan Li, Hannaneh Hajishirzi, Hao Cheng, Kai-Wei Chang, Erwan Michel, et al. Mathvista: Evaluating mathematical reasoning of foundation models in visual contexts. In *International Conference on Learning Representations*, 2024.
 - [33] Yifan Li, Yifan Du, Kun Zhou, Jinpeng Wang, Wayne Xin Zhao, and Ji-Rong Wen. Evaluating object hallucination in large vision-language models. *arXiv preprint arXiv:2305.10355*, 2023.
 - [34] Ke Chen, Jashuo Zhang, Bing Lin, Zhiang Zhao, and Jiaya Lin. Shikra: Unleashing multimodal llm’s referential dialogue magic. *arXiv preprint arXiv:2306.15195*, 2023.
 - [35] François Chollet. On the measure of intelligence. *arXiv preprint arXiv:1911.01547*, 2019.
 - [36] Aarohi Srivastava, Abhinav Rastogi, Abhishek Rao, Abu Awal Md Shoeb, Abubakar Abid, Adam Fisch, Adam R Brown, Adam Santoro, Aditya Gupta, Adrià Garriga-Alonso, et al. Beyond the imitation game: Quantifying and extrapolating the capabilities of language models. *Transactions on Machine Learning Research*, 2023.
 - [37] R Thomas McCoy, Shunyu Yao, Dan Friedman, Matthew Hardy, and Thomas L Griffiths. Embers of autoregression: Understanding large language models through the problem they are trained to solve. *arXiv preprint arXiv:2309.13638*, 2023.
 - [38] Oscar Sainz, Jon Campos, Iker García-Ferrero, Julen Etxaniz, Oier Lopez de Lacalle, and Eneko Agirre. NLP evaluation in trouble: On the need to measure LLM data contamination for each benchmark. In *Findings of the Association for Computational Linguistics: EMNLP 2023*, pages 10776–10787, 2023.
 - [39] Giacomo Balloccu et al. Leakage and data contamination in large language models: A survey. *arXiv preprint*, 2024.
 - [40] Dan Hendrycks, Collin Burns, Saurav Kadavath, Akul Arora, Steven Basart, Eric Tang, Dawn Song, and Jacob Steinhardt. Measuring mathematical problem solving with the math dataset. In *Thirty-fifth Conference on Neural Information Processing Systems Datasets and Benchmarks Track*, 2021.
 - [41] William G Hayward and Michael J Tarr. Spatial language and spatial representation. *Cognition*, 55(1):39–84, 1995.
 - [42] J Chen, Anthony G. Cohn, et al. A survey of qualitative spatial representations. *Spatial Cognition & Computation*, 2015.
 - [43] Patrick J Hayes. The second naive physics manifesto. In *Formal theories of the commonsense world*, pages 1–36. Intellect Books, 1985.
 - [44] Brenden M Lake and Marco Baroni. Generalization without systematicity: On the compositional skills of sequence-to-sequence recurrent networks. In *International Conference on Machine Learning*, pages 2873–2882. PMLR, 2018.
 - [45] Laura Ruis, Jacob Andreas, Marco Baroni, Diane Bouchacourt, and Brenden M Lake. A benchmark for systematic generalization in grounded language understanding. In *Advances in Neural Information Processing Systems*, volume 33, pages 19861–19872, 2020.
 - [46] Freda Shi et al. Language models are not strictly falling short: Multi-hop spatial reasoning benchmarks. In *Empirical Methods in Natural Language Processing (EMNLP)*, 2022.

- [47] X. Li et al. Neuro-symbolic integration for spatial reasoning in large multimodal models. *arXiv preprint*, 2024.
- [48] Jerry A Fodor and Zenon W Pylyshyn. Connectionism and cognitive architecture: A critical analysis. *Cognition*, 28(1-2):3–71, 1988.
- [49] Barbara H Partee. Compositionality in formal semantics. In *The Handbook of Contemporary Semantic Theory*. Blackwell, 2008.
- [50] Dieuwke Hupkes, Verna Dankers, Mathijs Mul, and Elia Bruni. Compositionality decomposed: How do neural networks generalise? *Journal of Artificial Intelligence Research*, 67:757–795, 2020.
- [51] Z. Yang et al. Neuro-symbolic language modeling for compositional generalization. *arXiv preprint*, 2023.
- [52] Catherine Olsson, Nelson Elhage, Neel Nanda, Nicholas Joseph, Nova DasSarma, Tom Henighan, Ben Mann, Amanda Askell, Yuntao Bai, Anna Chen, et al. In-context learning and induction heads. *Transformer Circuits Thread*, 2022.
- [53] Robin Manhaeve, Sebastijan Dumancic, Angelika Kimmig, Thomas Demeester, and Luc De Raedt. Deepproblog: Neural probabilistic logic programming. *Artificial Intelligence*, 298:103504, 2021.
- [54] Lachlan McPheat, Navdeep Kaur, Robert Blackwell, Alessandra Russo, Anthony G. Cohn, and Pranava Madhyastha. Decompsr: A dataset for decomposed analyses of compositional multihop spatial reasoning. *arXiv preprint arXiv:2511.02627*, 2025.